

UNIP

UNIVERSIDADE PAULISTA

Cloud Computing e DevOps

Autora: Profa. Jacqueline Zonichenn dos Reis

Colaboradoras: Profa. Gislaine Stachissini Barros

Profa. Larissa Rodrigues Damiani

Professora conteudista: Jacqueline Zonichenn dos Reis

Doutora em Engenharia de Produção pela Universidade Paulista (UNIP) (2022) e mestre em Engenharia de Produção pela mesma instituição (2019). MBA Executivo pelo IBMEC (2006). Pós-graduada em Gerência de Telecomunicações e Redes de Computadores pela Fumec (2003). Bacharel em Administração de Sistemas de Informação pela UNA-MG (2001). Técnica em Informática Industrial pelo Cefet-MG (1995). Possui certificações Cisco CCNA, Cisco CCDA, Cisco Cybersecurity Operations Fundamentals, Fortinet NSE4 e ITIL V4. Possui quatro anos de experiência como docente no ensino superior e mais de 25 anos de experiência na área de Telecomunicações, com atuação nas áreas técnica e comercial. Atualmente trabalha como Arquiteta de Soluções na Orange Business, empresa do grupo multinacional France Telecom. Professora do Curso Superior de Tecnologia em Gestão da Tecnologia da Informação e em Análise e Desenvolvimento de Sistemas na UNIP, nas modalidades presencial e EaD. Professora do Curso Superior em Ciências da Computação na UNIP na modalidade presencial. Autora de vários artigos sobre internet de serviços e indústria 4.0 em revistas científicas. Foi coautora dos livros *Indústria 4.0: conceitos e fundamentos* e *Transformação digital e indústria 4.0: produção e sociedade*, tendo sido esse último um dos livros finalistas ao prêmio Jabuti Acadêmico de 2024. Sua tese de doutorado, intitulada *Internet de serviços para inovação em modelos de negócios e transformação digital: aplicação para indústria 4.0 e agricultura 4.0*, foi premiada e indicada à Capes pela UNIP como melhor tese defendida no ano de 2022.

Dados Internacionais de Catalogação na Publicação (CIP)

R375c Reis, Jacqueline Zonichenn dos.

Cloud computing e DevOps / Jacqueline Zonichenn dos Reis. –
São Paulo: Editora Sol, 2026.

224 p., il.

Nota: este volume está publicado nos Cadernos de Estudos e
Pesquisas da UNIP, Série Didática, ISSN 1517-9230.

1. Computação em nuvem. 2. DevOps. 3. Arquitetura. I. Título.

CDU 681.324

U525.15 – 26

Prof. João Carlos Di Genio
Fundador

Profa. Sandra Rejane Gomes Miessa
Reitora

Profa. Dra. Marília Ancona Lopez
Vice-Reitora de Graduação

Profa. Dra. Marina Ancona Lopez Soligo
Vice-Reitora de Pós-Graduação e Pesquisa

Profa. Dra. Claudia Meucci Andreatini
Vice-Reitora de Administração e Finanças

Profa. M. Maria Cecília Migliaccio
Vice-Reitora de Extensão

Prof. Fábio Romeu de Carvalho
Vice-Reitor de Planejamento

Prof. Marcus Vinícius Mathias
Vice-Reitor das Unidades Universitárias

Profa. Silvia Renata Gomes Miessa
Vice-Reitora de Recursos Humanos e de Pessoal

Profa. Laura Ancona Lee
Vice-Reitora de Relações Internacionais

Profa. Melânia Dalla Torre
Vice-Reitora de Assuntos da Comunidade Universitária

UNIP EaD

Profa. Elisabete Brihy
Profa. M. Isabel Cristina Satie Yoshida Tonetto

Material Didático

Comissão editorial:

Profa. Dra. Christiane Mazur Doi
Profa. Dra. Ronilda Ribeiro

Apoio:

Profa. Cláudia Regina Baptista
Profa. M. Deise Alcantara Carreiro
Profa. Ana Paula Tôrres de Novaes Menezes

Projeto gráfico:

Prof. Alexandre Ponzetto

Revisão:

Deirdree Sousa
Vitor Andrade

Sumário

Cloud Computing e DevOps

APRESENTAÇÃO	9
INTRODUÇÃO	10

Unidade I

1 FUNDAMENTOS DA COMPUTAÇÃO EM NUVEM	13
1.1 Conceitos de computação em nuvem	13
1.2 Histórico da computação em nuvem	16
1.2.1 Mainframe	18
1.2.2 Arquitetura cliente-servidor	18
1.2.3 Virtualização	20
1.2.4 Utility computing	22
1.2.5 Cloud computing	25
1.2.6 Fog computing	28
1.2.7 Edge computing	30
1.3 Expansão e adoção da computação em nuvem	33
1.4 Principais características da computação em nuvem	36
1.4.1 Amplo acesso à rede	38
1.4.2 Rápida elasticidade	40
1.4.3 Serviços medidos	41
1.4.4 Self service sob demanda	43
1.4.5 Pool de recursos	44
2 MODELOS DE COMPUTAÇÃO EM NUVEM	46
2.1 Modelos de serviço	47
2.1.1 Infrastructure as a service (IaaS)	48
2.1.2 Platform as a service (PaaS)	50
2.1.3 Software as a service (SaaS)	51
2.1.4 Comparação dos modelos de serviço de computação em nuvem	53
2.2 Modelos de implantação	55
2.2.1 Nuvem pública	56
2.2.2 Nuvem privada	57
2.2.3 Nuvem híbrida	57
2.2.4 Nuvem comunitária	58
2.3 Principais provedores e serviços em nuvem do mercado	59
2.3.1 Amazon Web Services (AWS)	63
2.3.2 Microsoft Azure	66
2.3.3 Google Cloud Platform (GCP)	68

2.4 Impacto da nuvem no ambiente corporativo.....	71
2.5 Panorama atual: do on-premises ao multicloud.....	73

Unidade II

3 BENEFÍCIOS DA COMPUTAÇÃO EM NUVEM.....	79
3.1 Colaboração e trabalho remoto.....	79
3.2 Automação e monitoramento	82
3.3 Eficiência energética e sustentabilidade.....	86
3.4 Vantagens para a otimização de custos e recursos.....	88
3.4.1 Modelo de pagamento sob demanda.....	89
3.4.2 Elasticidade.....	91
3.4.3 Escalabilidade e competitividade	93
3.5 Importância da nuvem para a transformação digital	94
4 DESAFIOS DA COMPUTAÇÃO EM NUVEM.....	98
4.1 Segurança de dados.....	99
4.1.1 Perda de controle físico e lógico sobre os dados.....	102
4.1.2 Ameaças internas e externas	105
4.1.3 Criptografia e autenticação.....	107
4.2 Disponibilidade.....	109
4.3 Interoperabilidade e gerenciamento de múltiplos provedores.....	112
4.4 Lei Geral de Proteção de Dados Pessoais (LGPD).....	114

Unidade III

5 INFRAESTRUTURA E ESTRATÉGIA DE MIGRAÇÃO PARA A NUVEM	123
5.1 Modernização da infraestrutura e operação.....	124
5.1.1 Infraestrutura de data centers	124
5.1.2 Armazenamento e automação de recursos.....	127
5.1.3 Virtualização, contêineres, docker, kubernetes e orquestração	130
5.2 Planejamento de migração	133
5.2.1 Avaliação de necessidades.....	135
5.2.2 Escolha da arquitetura de aplicação e modelo de nuvem	136
5.2.3 Definição da abordagem de migração para a nuvem.....	138
5.2.4 Execução e monitoramento do desempenho	140
6 ARQUITETURA E INTEGRAÇÃO DE APLICAÇÕES EM NUVEM	141
6.1 Arquitetura de aplicações na nuvem	142
6.1.1 Evolução para microsserviços.....	142
6.1.2 APIs.....	147
6.1.3 Cloud-native.....	148
6.2 Integração com sistemas legados (on-premises + nuvem)	150
6.3 Gestão de serviços em nuvem	153
6.3.1 Monitoramento e controle de performance dos serviços em nuvem.....	153
6.3.2 Governança de dados em nuvem	156
6.4 Aplicações e casos de uso em diferentes setores.....	157
6.4.1 Agricultura.....	157

6.4.2 Indústria de manufatura.....	161
6.4.3 Smart cities	166
6.4.4 Healthcare.....	169
6.4.5 Educação	172
6.4.6 Entretenimento.....	175

Unidade IV

7 DEVOPS: CONCEITOS E PRÁTICAS.....	183
7.1 Evolução de desenvolvimento para o DevOps.....	183
7.2 Fundamentos de DevOps: princípios, cultura e processos.....	188
7.3 Ferramentas e práticas essenciais.....	194
7.3.1 Integração contínua (CI).....	194
7.3.2 Entrega contínua (CD)	195
7.3.3 Pipelines automatizados.....	195
7.3.4 Integração e entrega contínua (CI e CD) com docker e azure kubernetes service ...	196
7.3.5 Infraestrutura como código (IaC).....	197
7.3.6 Gestão de configuração	198
7.4 Integração entre desenvolvimento e operações.....	198
8 INOVAÇÃO E FUTURO DA COMPUTAÇÃO EM NUVEM E DEVOPS.....	201
8.1 Integração com IA.....	202
8.2 Computação quântica.....	205
8.3 Tendências em computação em nuvem	206
8.3.1 Serverless.....	206
8.3.2 Expansão do edge computing	207
8.3.3 Green cloud e sustentabilidade	209
8.4 Tendências em DevOps.....	211
8.4.1 DevSecOps	211
8.4.2 GitOps.....	212
8.4.3 FinOps.....	213

APRESENTAÇÃO

Prezado(a) aluno(a),

Esta disciplina apresenta os conceitos fundamentais da computação em nuvem e das práticas de DevOps, mostrando como essas duas abordagens se complementam para viabilizar o desenvolvimento, a integração e a operação de sistemas modernos. Por meio de uma linguagem clara e didática, os fundamentos e modelos de nuvem tornam-se mais acessíveis, permitindo compreender como essa infraestrutura, aparentemente complexa, sustenta aplicações escaláveis e processos de entrega contínua (CD, do inglês, continuous delivery) de software.

O objetivo é oferecer uma visão abrangente da computação em nuvem aliada às práticas DevOps, capacitando o estudante a entender os vários tipos de serviços em nuvem, bem como a implementar e gerenciar as aplicações distribuídas. O conteúdo possibilita o pensamento crítico sobre como arquiteturas cloud, automação e pipelines de integração e entrega podem acelerar o ciclo de vida de desenvolvimento, aumentar a qualidade do software e otimizar a operação de serviços.

Durante a disciplina, exploraremos os principais modelos de serviço em nuvem (IaaS, PaaS e SaaS) e suas possibilidades para criação de aplicações nativas de nuvem. Serão abordados componentes físicos, lógicos e de rede, além de ferramentas e serviços dos principais provedores do mercado. Discutiremos práticas essenciais de orquestração, infraestrutura como código (IaC), monitoramento e escalabilidade, pontos-chave para o desenvolvimento e operações que seguem a cultura DevOps.

O livro-texto conecta a evolução da computação em nuvem às metodologias e ferramentas DevOps, detalhando tópicos como microsserviços, interface de programação de aplicações (APIs, do inglês, interface application programming), pipelines automatizados, integração e CD. Essa perspectiva demonstra como tecnologias de virtualização, sistemas distribuídos e data centers deram origem aos ambientes cloud atuais e como as práticas de DevOps potencializam a agilidade e a confiabilidade nesses contextos.

Além da base conceitual, a disciplina apresenta casos de uso e exemplos práticos de integração entre soluções em nuvem e sistemas corporativos, mostrando como diferentes setores, seja manufatura, mobilidade urbana, cidades inteligentes, educação ou saúde utilizam cloud computing e DevOps para acelerar a inovação, reduzir custos e garantir alta disponibilidade.

Elemento central da transformação digital, a computação em nuvem fornece recursos sob demanda, enquanto o DevOps promove colaboração entre equipes de desenvolvimento e operação, possibilitando entregas rápidas, contínuas e seguras. Investir nessas práticas é essencial para criar aplicações de alto desempenho e manter a competitividade em um mercado em constante evolução.

Esta disciplina proporciona, portanto, não apenas a compreensão dos fundamentos de nuvem e DevOps, mas também a capacidade de projetar arquiteturas de cloud, implementar automações, integrar sistemas e gerenciar serviços em ambientes distribuídos. O conhecimento adquirido será valioso para você, aluno, em sua atuação profissional no desenvolvimento, implantação e operação de soluções baseadas em nuvem.

Conforme avançamos para um cenário cada vez mais interconectado, a computação em nuvem introduz novos paradigmas. A possibilidade de acessar e integrar dados e serviços nesse ambiente torna os sistemas mais escaláveis, resilientes e disponíveis em nível global. Para tirar pleno proveito dessas capacidades, os desenvolvedores e demais profissionais da área precisam compreender os conceitos essenciais e a complexidade inerente às operações em nuvem, garantindo o desenvolvimento de soluções que explorem todo o seu potencial.

Boa leitura!

INTRODUÇÃO

Nestas primeiras décadas do século XXI, uma série de avanços em redes de alta velocidade, capacidade de armazenamento, automação de TI e consolidação de hardware transformou profundamente a forma como desenvolvemos, integramos e operamos sistemas.

Foram inúmeras as inovações, dentre as quais a virtualização representou um marco histórico. Ao separar o software do hardware físico, ela tornou possível executar múltiplas máquinas virtuais (VMs) em um único servidor, aumentando a eficiência e a disponibilidade dos data centers. Esta inovação tecnológica abriu caminho para a computação em nuvem, que leva a virtualização a um novo patamar ao disponibilizar infraestrutura, plataformas e software como serviços escaláveis e acessíveis sob demanda.

A computação em nuvem não é apenas uma mudança de arquitetura; ela redefine como aplicações são projetadas, entregues e mantidas, integrando recursos distribuídos em escala global e suportando modelos modernos de desenvolvimento. Em paralelo, o DevOps surge como uma prática cultural e técnica que aproxima equipes de desenvolvimento e operações, permitindo entrega contínua de software, automação de ambientes e integração constante. Juntas, Cloud e DevOps formam o núcleo da inovação digital atual.

Este livro-texto apresenta quatro unidades, ligando teoria à prática e abordando computação em nuvem e DevOps da forma explanada a seguir.

A unidade I introduz os alicerces conceituais da computação em nuvem, permitindo que o leitor compreenda com clareza a definição, as principais características e a evolução histórica desse paradigma. Parte-se de um panorama da computação centralizada em mainframes, passando pela consolidação da arquitetura cliente-servidor e pelo avanço decisivo da virtualização, elementos que abriram caminho para a abstração de recursos e para o uso mais eficiente da infraestrutura. Em seguida, explora-se o surgimento do conceito de utility computing, que popularizou a ideia de "TI como serviço" e preparou o terreno para a nuvem moderna. A unidade aprofunda ainda as transformações que levaram à popularização da nuvem, analisa os modelos de borda, como edge e fog computing, e apresenta os diferentes modelos de serviço (IaaS, PaaS e SaaS) e de implantação (pública, privada, híbrida e comunitária). Por fim, discute o cenário contemporâneo que vai do on-premises ao multicloud, destacando como essas arquiteturas impactam a transformação digital das organizações.

A unidade II aprofunda os ganhos práticos e estratégicos proporcionados pela adoção da nuvem, evidenciando como a elasticidade, a escalabilidade e o modelo de pagamento sob demanda contribuem para a otimização de custos e para a competitividade empresarial. São analisadas as vantagens para colaboração e trabalho remoto, o papel da automação e do monitoramento na redução de falhas operacionais e o impacto positivo da nuvem na eficiência energética e na sustentabilidade corporativa. Paralelamente, o texto apresenta também os desafios críticos que acompanham a adoção desse modelo: a perda de controle físico e lógico sobre os dados, as ameaças internas e externas em ambientes multitenancy, a necessidade de criptografia, autenticação forte e políticas de governança. Também são exploradas estratégias de alta disponibilidade, como tolerância a falhas, backup e disaster recovery, e discutidas as obrigações legais impostas pela Lei Geral de Proteção de Dados (LGPD) e normas internacionais de privacidade. A unidade fornece, assim, uma visão equilibrada que combina oportunidades e riscos, capacitando o leitor a avaliar e mitigar ameaças em projetos de computação em nuvem.

A unidade III traz um roteiro detalhado para planejamento, migração e operação de serviços em nuvem, alinhando decisões tecnológicas aos objetivos de negócio. Inicia-se com a análise de infraestrutura, abordando a arquitetura de data centers, redes de alta disponibilidade, mecanismos de armazenamento escalável e o papel da automação para garantir eficiência e resiliência. São exploradas práticas de virtualização, contêineres (Docker, Kubernetes) e orquestração, fundamentais para implantações modernas. Em seguida, o conteúdo orienta o leitor na avaliação de necessidades, definição de metas, gestão de mudanças e adaptação de processos organizacionais, incluindo a negociação de contratos, SLAs e requisitos de compliance. O estudo avança para o desenvolvimento e a integração de aplicações nativas de nuvem, destacando microsserviços, APIs e plataformas de integração (iPaaS), bem como estratégias de convivência com sistemas legados em ambientes híbridos. A unidade finaliza com práticas de monitoramento, governança de dados e controle de performance, além de apresentar casos de uso em setores como agricultura, manufatura, cidades inteligentes, saúde, educação e entretenimento, demonstrando a amplitude e a aplicabilidade da nuvem em diferentes contextos.

A unidade IV introduz a cultura DevOps como fator-chave para acelerar a entrega de software e integrar equipes de desenvolvimento e operações. São discutidos seus fundamentos, princípios de colaboração contínua e as ferramentas essenciais que sustentam essa prática: integração contínua (CI, do inglês, continuous integration), CD, IaC, pipelines automatizados e gestão de configuração. A unidade também destaca a evolução para abordagens como DevSecOps, que incorpora segurança desde o início do ciclo de vida, GitOps para automação baseada em git e FinOps para otimização de custos em ambientes cloud. Na fronteira da inovação, o texto aborda tendências que moldarão o futuro da área, como arquiteturas serverless, a expansão do edge computing, estratégias de green cloud focadas em sustentabilidade e a aplicação da computação quântica. Além disso, discute a integração de inteligência artificial (IA) em pipelines DevOps, abrindo caminho para uma automação ainda mais sofisticada. Essa abordagem permite ao leitor compreender não apenas o estado atual, mas também os rumos da computação em nuvem e do DevOps como motores de transformação digital e competitividade organizacional.

Ao final do estudo, o leitor será capaz de:

- Compreender os fundamentos da computação em nuvem e sua relação com sistemas distribuídos.

- Projetar e integrar aplicações em ambientes cloud, utilizando práticas de contêineres, orquestração e microsserviços.
- Aplicar DevOps para automação, CI e CD, garantindo alta disponibilidade e qualidade do software.
- Avaliar e executar estratégias de migração para a nuvem, alinhando-as a metas técnicas e de negócio.
- Gerenciar e monitorar serviços em nuvem com segurança, escalabilidade e governança de dados.
- Explorar tendências emergentes, como serverless, edge computing e green cloud, antecipando demandas de um mercado em rápida evolução.

Com a demanda crescente e contínua por novas ferramentas e aplicações, a combinação de computação em nuvem e DevOps é indispensável para criar ambientes resilientes, escaláveis e seguros. Essa dupla potencializa a colaboração entre equipes, acelera a entrega de software e sustenta a adoção de tecnologias emergentes como Internet das Coisas (IoT), IA e análise de big data.

Dominar esses conceitos capacita o profissional a desenvolver, integrar e operar sistemas distribuídos de forma eficiente e alinhada às necessidades de organizações de qualquer porte, preparando-o para desafios e oportunidades da transformação digital.

Bom estudo!

Unidade I

1 FUNDAMENTOS DA COMPUTAÇÃO EM NUVEM

A forma como empresas e pessoas utilizam a tecnologia da informação (TI) vem passando por mudanças contínuas. A computação em nuvem surgiu para superar as limitações dos modelos tradicionais, em que cada organização precisava investir e manter sua própria estrutura de servidores, armazenamento e software.

Com a nuvem, criou-se um novo paradigma: os recursos são virtualizados, podendo ser ampliados ou reduzidos conforme a demanda, e estão disponíveis sob requisição, permitindo que usuários e companhias acessem tecnologias avançadas sem se preocupar com aquisição, manutenção ou espaço físico. Esse modelo não só reduz custos e aumenta a flexibilidade, como também traz novas perspectivas para conceitos clássicos de sistemas distribuídos, tolerância a falhas e alta disponibilidade.

Nesta unidade, abordaremos os princípios básicos da computação em nuvem, suas principais características, os diferentes tipos de serviços e a trajetória de sua evolução, evidenciando como ela se consolidou como elemento essencial da infraestrutura de TI contemporânea.

1.1 Conceitos de computação em nuvem

A computação em nuvem (do inglês, cloud computing) é um modelo de disponibilização de recursos de TI pela internet, oferecendo infraestrutura, plataformas e software como serviço (software as a service – SaaS) (Veras, 2015).

Trata-se de um conjunto de soluções que fornecem serviços sob demanda, apoiando-se em diversos recursos e sistemas de computação (Silva, 2021). Como mostrado na figura a seguir, esses serviços podem abranger aplicações, plataformas e infraestrutura, todos conectados e entregues de maneira integrada por redes de comunicação de alta capacidade, acessíveis aos usuários.




Figura 1 – Computação em nuvem

Adaptada de: <https://tinyurl.com/yc5ymsbn>. Acesso em: 18 maio 2026.

A computação em nuvem oferece recursos como servidores, armazenamento, redes e bancos de dados em formato de serviço, contratados sob demanda, com possibilidade de expansão e cobrança baseada no uso. Em vez de adquirir servidores e manter toda a infraestrutura física em suas instalações, as organizações podem acessar esses recursos em ambientes virtuais, escaláveis e administrados por provedores de nuvem.

Esses provedores são empresas especializadas em disponibilizar serviços de computação em nuvem (Kolbe Júnior, 2020). Entre os principais estão Amazon (AWS), Microsoft (Azure) e Google (Google Cloud). Cabe a eles desenvolver e operar toda a infraestrutura necessária, geralmente distribuída em salas de data centers, compostas por grandes instalações físicas espalhadas geograficamente, que abrigam servidores, sistemas de armazenamento, equipamentos de rede e mecanismos de segurança, como ilustrado na figura a seguir.




Figura 2 – Data center

Disponível em: <https://tinyurl.com/3cwvts2h>. Acesso em: 18 maio 2026.

O termo "nuvem" se refere a esses grandes data centers acessíveis pela internet que podem operar em modelos públicos, privados ou híbridos, oferecendo escalabilidade, flexibilidade e disponibilidade contínua aos usuários.

Toda essa estrutura permite a entrega de recursos virtualizados e escaláveis, disponibilizados ao cliente como serviços em nuvem. Dessa forma, a alocação ou liberação dos serviços é feita conforme a necessidade do cliente, sem depender de aquisição ou instalação física de hardware próprio.



Lembrete

A computação em nuvem consiste em um modelo de fornecimento de recursos de TI pela internet, disponibilizando infraestrutura, plataformas e softwares como serviços (Veras, 2015).

Imagine que você precise montar toda a infraestrutura de TI da sua empresa. Isso significaria adquirir servidores físicos, investir em sistemas de refrigeração, planejar energia redundante, providenciar backups e manter equipes especializadas apenas para cuidar da segurança, atualização e disponibilidade desses equipamentos. Nesse cenário, cada detalhe estaria sob sua responsabilidade: desde proteger os dados contra invasões e falhas de hardware até garantir que os serviços fiquem disponíveis 24 horas por dia, 7 dias por semana. On-premise (ou on-premises) é o nome dado a esse modelo em que toda a infraestrutura de TI (servidores, sistemas, armazenamento, rede e segurança) fica instalada fisicamente dentro da própria empresa.

Além do investimento inicial elevado, seria necessário prever o crescimento da demanda. Isto significa que se os acessos aumentarem além do esperado, você teria que comprar mais servidores, espaço físico e ampliar a equipe de suporte. Em contrapartida, se de repente a demanda cair, parte desse investimento ficaria ocioso, gerando desperdício e gastos desnecessários.

Agora compare com o modelo de computação em nuvem: ao invés de investir em toda essa estrutura, você contrata os recursos sob demanda, com escalabilidade imediata e toda a parte de segurança, disponibilidade e manutenção já sendo garantida pelo provedor.

Um dos diferenciais dos serviços em nuvem está, portanto, na forma com que eles são contratados, ou seja, no modelo de pagamento que segue o formato on-demand. Nesse modelo, o cliente paga apenas por aquilo que ele utiliza. Essa flexibilidade e possibilidade de escalabilidade com economia, através do pagamento somente daquilo que é consumido, se torna um dos principais ganhos que a computação em nuvem proporciona para as organizações.

A disponibilidade segue o princípio Just in Time, garantindo acesso contínuo (24 horas por dia, 7 dias por semana, 365 dias por ano) de forma online, o que amplia a funcionalidade do ambiente. Os recursos funcionam de forma integrada, oferecendo ao usuário a impressão de um único sistema central, o que caracteriza a computação em nuvem como uma aplicação de sistema distribuído.



Observação

Um sistema distribuído é composto por diversos computadores independentes, possivelmente heterogêneos em termos de hardware e software, interligados por uma rede de comunicação. Apesar dessa diversidade, eles se apresentam aos usuários como um sistema único, integrado e coerente (Tanenbaum; Steen, 2007).

Outro aspecto essencial é o acesso por meio de uma interface gráfica de interação humano-máquina (ou human machine interface – HMI), que deve oferecer alta qualidade visual, atratividade e usabilidade. Isso significa facilidade de navegação, taxa elevada de sucesso nas operações e, consequentemente, maior satisfação do usuário ao explorar a infraestrutura digital.

A computação em nuvem representa um avanço essencial para o desenvolvimento de sistemas modernos, pois substitui a necessidade de grandes investimentos em infraestrutura on premise por recursos flexíveis e sob demanda. Esse modelo permite que desenvolvedores tenham acesso a ferramentas, plataformas e ambientes escaláveis diretamente pela internet, facilitando a criação de aplicações robustas e adaptáveis.

Com a nuvem, torna-se possível implementar arquiteturas que exploram elasticidade, alcance global e alta disponibilidade, permitindo que aplicações sejam ajustadas conforme a variação de carga e atendam usuários em diferentes regiões do mundo. Além disso, o provisionamento automatizado e a integração com serviços de monitoramento e segurança tornam o ciclo de desenvolvimento mais ágil e confiável.

A adoção da nuvem também transforma a forma como os sistemas são projetados: a utilização de microsserviços, contêineres e APIs promove modularidade, manutenção facilitada e maior portabilidade entre ambientes. Assim, os desenvolvedores podem experimentar, evoluir e descartar soluções rapidamente, reduzindo riscos e acelerando a entrega de valor por meio do software.

Nesse sentido, a computação em nuvem deixa de ser apenas um recurso tecnológico e se consolida como a base para práticas modernas de desenvolvimento, como o DevOps, que viabiliza a automação de testes, CI e deploy frequente de aplicações.

1.2 Histórico da computação em nuvem

A trajetória da computação em nuvem está diretamente ligada ao avanço dos computadores, marcada pelo barateamento dos componentes de hardware e pelo progresso das tecnologias de rede e telecomunicações. A combinação de equipamentos mais acessíveis com conexões mais rápidas e econômicas possibilitou a criação de data centers e de soluções sofisticadas, como os servidores responsáveis por hospedar serviços em nuvem. Isso abriu espaço para o acesso remoto a recursos computacionais por meio da internet, mudando radicalmente a maneira como as organizações utilizam a tecnologia.

Cada categoria de computador possui pontos fortes, limitações e usos mais apropriados, desde o mainframe, reconhecido por sua confiabilidade, até os computadores quânticos, ainda emergentes, passando por clusters, grids e arquiteturas de nevoeiro e borda. Vale destacar que essas tecnologias não se excluem mutuamente. Muitas vezes, são combinadas para atender diferentes necessidades em um mesmo ecossistema de TI. Um exemplo é o uso de mainframes para operações críticas, clusters para tarefas de alto desempenho, nuvem para flexibilidade e escalabilidade, e soluções de borda para lidar com dados de dispositivos IoT próximos à origem. Essa diversidade tecnológica reflete a variedade de

problemas a serem solucionados. Ao compreender as particularidades de cada arquitetura, é possível selecionar a mais adequada a cada cenário e maximizar o potencial da computação.

Ao longo das últimas décadas, esse processo de evolução da computação se tornou evidente, como pode ser visualizado na figura a seguir.




Figura 3 – Evolução da computação

Adaptada de: Bruno e Jordan (2011).

Entre os anos 1960 e 1970, predominava a arquitetura centralizada, em que os mainframes concentravam o processamento e o armazenamento de dados. Os usuários acessavam essas máquinas por meio dos chamados terminais "burros", equipamentos formados basicamente por teclado e monitor conectados ao mainframe via linhas seriais. Esses terminais recebiam esse nome por não realizarem processamento nem armazenarem informações, sua função era apenas transmitir os comandos do usuário e exibir as respostas fornecidas pelo computador central.

Nas décadas de 1980 e 1990, vem a popularização dos minicomputadores e dos computadores pessoais. O processamento, que antes era totalmente centralizado, começou a se tornar distribuído. Nessa fase, cada departamento ou aplicação passou a contar com seu próprio servidor, dando origem a uma arquitetura descentralizada, cuja principal forma de implementação foi o modelo cliente-servidor. Nesse arranjo, os sistemas de negócio eram instalados em servidores e acessados pelos usuários por meio de softwares clientes em seus PCs. A distribuição dos aplicativos também era impulsionada pelo alto custo das conexões WAN e pelas limitações de desempenho, além do preço elevado dos mainframes, que inviabilizava seu uso como alternativa ao modelo cliente-servidor.

A partir dos anos 2000, a arquitetura evolui novamente, agora baseada em consolidação e virtualização. O barateamento dos equipamentos de comunicação, somado ao aumento da capacidade computacional, favoreceu a centralização em data centers, que se mostraram mais econômicos em relação à abordagem distribuída. Essa nova etapa foi marcada pelo uso intensivo de virtualização e automação, preparando o terreno para o surgimento da computação em nuvem, em suas modalidades pública e privada.

Antes de avançarmos no estudo da computação em nuvem, é importante compreender melhor cada uma dessas arquiteturas, pois elas representam marcos fundamentais na trajetória da evolução da computação.

1.2.1 Mainframe

Os mainframes são computadores de grande porte projetados para lidar com grandes volumes de dados de maneira ágil e eficiente. São especialmente utilizados em aplicações que exigem alto nível de disponibilidade, confiabilidade e segurança, como o processamento de transações financeiras, o gerenciamento de sistemas hospitalares e a operação de companhias aéreas (Silva, 2024).

A história dos mainframes remonta às origens da computação. O termo surgiu para designar o gabinete principal que abrigava a CPU, mas, ao longo do tempo, passou a se referir a computadores potentes, capazes de suportar milhares de usuários e aplicações ao mesmo tempo.

Um dos principais atributos dos mainframes é sua confiabilidade. Eles são construídos para funcionar continuamente, com recursos de redundância que permitem manter as operações mesmo diante da falha de algum componente. Além disso, possuem alta capacidade de processamento de transações em grande escala, tornando-se indispensáveis em cenários que demandam desempenho elevado.

Outro diferencial é a robustez em termos de segurança. Esses sistemas contam com múltiplas camadas de proteção, como controles de acesso, criptografia e isolamento de processos, garantindo a integridade dos dados e aplicações sob sua responsabilidade.

Apesar da ascensão de novas tecnologias, como a computação em nuvem, os mainframes seguem desempenhando um papel essencial na infraestrutura de TI. Segundo relatório da Forbes de 2024, mais de 70% das empresas listadas na Fortune 500 ainda dependem deles para suas operações críticas (Silva, 2024).

Entretanto, existem desafios associados ao seu uso. A falta de profissionais especializados em mainframe é uma preocupação crescente, já que muitos profissionais de TI atuais não possuem familiaridade com essa tecnologia. Além disso, embora reconhecidos por sua segurança e estabilidade, esses sistemas estão sujeitos a falhas e ameaças cibernéticas.

Em síntese, os mainframes continuam sendo parte fundamental da estrutura tecnológica de diversas organizações. Eles reúnem disponibilidade, confiabilidade, alto desempenho e segurança; características essenciais para aplicações que precisam processar grandes quantidades de dados com rapidez e precisão.

1.2.2 Arquitetura cliente-servidor

Na arquitetura cliente-servidor, o processamento deixa de ser totalmente centralizado, como acontecia nos mainframes tradicionais, e passa a ser distribuído entre diferentes máquinas. Esse modelo introduz uma divisão clara de responsabilidades: um ou mais computadores assumem o papel de servidores, oferecendo serviços de rede, como acesso a aplicativos ou gerenciamento de impressoras; enquanto os demais, chamados de clientes, requisitam esses serviços.

Nessa configuração, os clientes (geralmente PCs) executam parte do trabalho, como a interface gráfica e algumas validações locais, enquanto os servidores concentram funções mais críticas, como o gerenciamento de bancos de dados e a lógica central das aplicações. Dessa forma, a carga de processamento é compartilhada entre vários computadores.

A figura a seguir ilustra uma arquitetura cliente-servidor.




Figura 4 – Arquitetura cliente-servidor

Disponível em: <https://tinyurl.com/yyhb33jk>. Acesso em: 19 maio 2025.

Um servidor é um equipamento dedicado a fornecer recursos ou serviços para uma rede. Ele não é usado para funções genéricas, mas sim para desempenhar tarefas específicas, exigindo, para isso, alto poder de processamento e dispositivos de armazenamento rápidos e de grande capacidade.

Quando o servidor é exclusivo para uma única função, seu desempenho tende a ser superior, já que não divide recursos com outras atividades. Contudo, à medida que a quantidade de serviços de rede cresceu, tornou-se inviável concentrar tudo em um único computador. A solução encontrada foi o modelo cliente-servidor, no qual os serviços são distribuídos entre vários servidores e disponibilizados a diversos clientes.

Os computadores clientes, também chamados de estações de trabalho, funcionam como a interface entre os usuários e os serviços do servidor. Neles, os usuários podem acessar dados, executar aplicações locais e interagir com o sistema. O tipo de hardware dessas máquinas varia conforme as necessidades de processamento de cada aplicação ou informação a ser acessada.

Segundo Tanenbaum e Steen (2007), uma das funções fundamentais das máquinas clientes é possibilitar que os usuários interajam com servidores remotos. Essa interação pode acontecer de duas formas principais. A primeira é por meio de uma aplicação dedicada, em que cada serviço remoto possui um software específico instalado no cliente, responsável pela comunicação direta com o servidor. Um exemplo é o de uma agenda em um assistente digital pessoal (PDA, do inglês, personal digital assistant) que realiza a sincronização de seus dados com um calendário compartilhado em rede. A segunda forma é o uso de terminais de acesso, em que o cliente atua apenas como interface de interação, enquanto todo o processamento e armazenamento são realizados pelo servidor. Nesse modelo, o dispositivo não precisa manter dados localmente, funcionando como um thin client ("cliente magro, ou "cliente enxuto", expressões usadas quando a lógica está no servidor). Com o avanço da internet e a popularização dos dispositivos móveis, esse tipo de cliente enxuto tem se tornado cada vez mais relevante.

Já os servidores assumem um papel central na computação atual, servindo como a base estrutural de inúmeros sistemas de informação. São máquinas de alto desempenho, projetadas para armazenar e organizar dados, hospedar sites, executar aplicações e disponibilizar serviços para clientes e dispositivos conectados à rede. Dessa forma, fornecem os recursos e funções indispensáveis para o funcionamento de sistemas distribuídos e aplicações baseadas em rede.

Dentro de uma arquitetura cliente-servidor, é possível encontrar diferentes categorias de servidores, tais como:

- **Servidor de arquivos (file server):** responsável por armazenar e organizar arquivos, permitindo que sejam acessados e compartilhados entre os clientes da rede.
- **Servidor de banco de dados (database server):** gerencia bancos de dados e atende às consultas realizadas pelos clientes.
- **Servidor de impressão (print server):** administra impressoras em rede e gerencia a fila de trabalhos de impressão.
- **Servidor web (web server):** hospeda sites e distribui conteúdo web para os navegadores dos clientes.
- **Servidor de aplicação (application server):** processa a lógica de negócios das aplicações e responde às solicitações feitas pelos clientes.

Ao implementar uma rede baseada na arquitetura cliente-servidor, diversos desafios precisam ser considerados. Entre eles estão a proteção dos dados durante a transmissão entre clientes e servidores, a manutenção da disponibilidade e confiabilidade dos serviços mesmo diante de falhas, e a gestão eficiente do desempenho e da escalabilidade conforme aumenta o número de usuários. Além disso, é necessário lidar com a complexidade relacionada à manutenção e atualização dos servidores, bem como com os custos de infraestrutura e licenciamento de softwares, que podem ser elevados em grandes ambientes corporativos. Outro aspecto relevante é a adequação da rede e da largura de banda, já que o desempenho geral depende diretamente da capacidade de comunicação entre clientes e servidores.



Saiba mais

Para saber mais sobre arquitetura cliente-servidor, uma referência é:

TANENBAUM, A. S.; STEEN, M. *Sistemas distribuídos: princípios e paradigmas*. São Paulo: Pearson, 2007.

1.2.3 Virtualização

A virtualização permitiu que as empresas utilizassem seus recursos de hardware de maneira muito mais eficiente, separando o ambiente de software do equipamento físico. Com isso, os servidores passaram a existir como VMs representadas por arquivos, permitindo movê-los entre diferentes equipamentos, duplicá-los quando necessário e construir uma infraestrutura mais flexível e escalável.

Além disso, a virtualização possibilita a execução de múltiplos sistemas operacionais (SOs) em um único hardware. Essa abordagem não só otimiza o uso dos recursos, como também oferece benefícios

adicionais, como isolamento de aplicações, maior flexibilidade e facilidade na gestão de diversos ambientes computacionais (Smith; Nair, 2005).

Na virtualização completa, o hardware do sistema é totalmente emulado para cada sistema operacional convidado, de modo que ele pode ser executado sem qualquer modificação, como se estivesse rodando em um hardware físico dedicado. Uma das principais vantagens desse modelo é a compatibilidade: praticamente qualquer sistema operacional pode ser executado sem alterações. Outro benefício é a implantação mais rápida e simples de sistemas e aplicativos, já que não são necessários ajustes no software convidado.

Por outro lado, a emulação total do hardware pode gerar overhead significativo, causando perda de desempenho em comparação à execução direta em hardware físico. Isso ocorre porque a emulação demanda mais recursos, como CPU e memória, o que pode ser limitante em sistemas com capacidade restrita.

A virtualização oferece uma solução versátil e robusta para rodar vários sistemas operacionais em um único equipamento, mas essa flexibilidade pode resultar em maior consumo de recursos e desempenho reduzido. Quando se busca maior eficiência e aproveitamento de recursos, a virtualização se torna essencial, permitindo que um único dispositivo físico funcione como múltiplas instâncias independentes. Alguns tipos de virtualização também permitem integrar diferentes equipamentos físicos e apresentá-los como um único sistema lógico.

Os projetistas de redes enfrentam desafios crescentes, especialmente com a expansão rápida dos data centers, o que reforça a importância da virtualização. Entre os principais fatores que impulsionam sua adoção estão:

- **Redução de custos operacionais:** diminui despesas com energia e refrigeração, aumentando a produtividade.
- **Consolidação de equipamentos:** reduz o número de dispositivos físicos, concentrando tarefas individuais.
- **Isolamento de tráfego:** cria grupos de usuários separados e protegidos dentro da mesma rede.
- **Melhor relação custo/desempenho:** elimina hardware subutilizado que apresenta baixo retorno em desempenho.

Segundo Bruno e Jordan (2011), virtualização é um termo abrangente que engloba diversas tecnologias com o objetivo comum de abstrair elementos de hardware (como sistemas operacionais e aplicativos) ou de redes (como LANs e SANs) e executá-los em um estado virtual. Essa tecnologia traz diversos benefícios, desde a consolidação de recursos até o aumento da eficiência operacional.

Atualmente, a virtualização é um componente central das arquiteturas de data centers corporativos e está transformando a forma como esses centros são estruturados. Ela é amplamente utilizada em ambientes de nuvem, onde compatibilidade e facilidade de implantação são cruciais. O uso da virtualização aumenta a eficiência, oferece maior flexibilidade e ainda contribui para a redução de custos operacionais.



Lembrete

Os mainframes continuam presentes em diversos data centers, principalmente pelos benefícios que oferecem em termos de alta disponibilidade, resiliência e cumprimento de acordos de nível de serviço (SLA, do inglês, service level agreement).

Com a virtualização, os data centers tornaram-se mais disponíveis e produtivos, aproveitando melhor tanto os recursos quanto a capacidade da área de TI.

A chegada da computação em nuvem ampliou os benefícios proporcionados pela virtualização, levando esse nível de eficiência mais adiante. Nesse contexto, a nuvem se baseia em pools de recursos virtualizados, distribuídos geograficamente e acessíveis sob demanda, o que permite alocar processamento, armazenamento e rede de maneira dinâmica conforme a necessidade. Dessa forma, a computação em nuvem consolida a virtualização como pilar de uma arquitetura de TI mais escalável, flexível e resiliente.

1.2.4 Utility computing

O conceito de utility computing, ou computação como utilidade, constitui um marco relevante na evolução dos modelos de oferta de serviços em TI. Ele estabelece a ideia de que recursos computacionais como processamento, armazenamento e rede podem ser disponibilizados e consumidos de maneira semelhante a serviços públicos essenciais, como energia elétrica, água ou telefonia. Assim como ocorre no pagamento pelo consumo de energia, a proposta do utility computing é que as organizações arquem apenas com a capacidade computacional efetivamente utilizada.

Essa concepção surgiu como resposta às limitações e ineficiências dos modelos tradicionais de infraestrutura, especialmente aqueles fundamentados em servidores dedicados e exclusivos. A gestão de ambientes de TI complexos demandava investimentos elevados em hardware, software e equipes especializadas, além de custos expressivos com manutenção, energia elétrica e refrigeração. Em muitos casos, os recursos permaneciam subutilizados, o que resultava em desperdício e baixa eficiência operacional.

As raízes do conceito de utility computing remontam às décadas de 1950 e 1960, período marcado pelos primeiros mainframes compartilhados. Conforme discutido anteriormente, grandes centros de processamento de dados permitiam que múltiplas empresas ou departamentos utilizassem o mesmo equipamento por meio do time-sharing, técnica que distribuía o tempo de processamento entre vários usuários simultaneamente.

Nesse contexto, pesquisadores como John McCarthy, professor da Universidade de Stanford, já defendiam a noção de computação como serviço. Em 1961, durante o evento MIT Centennial, McCarthy afirmou que a computação poderia futuramente ser organizada como um serviço público, de forma semelhante ao sistema telefônico. Ele também destacou que os serviços de informática poderiam se tornar a base de uma nova e relevante indústria (Ferreira, 2012). Essa visão antecipava o modelo de fornecimento sob demanda que só se tornaria plenamente viável décadas depois, com o avanço das redes e das tecnologias de virtualização.

Afirma-se, portanto, que as primeiras ideias relacionadas à computação em nuvem surgem nesse período, a partir das discussões sobre utility computing, que propunha um modelo no qual provedores disponibilizariam infraestrutura e recursos computacionais conforme a necessidade dos clientes.

Alguns anos depois, em 1969, Leonard Kleinrock, então cientista-chefe da Advanced Research Projects Agency Network (Arpanet), declarou que as redes de computadores ainda estavam em estágio inicial, mas que, à medida que evoluíssem, possibilitariam a disseminação de "utilidades computacionais".

Essas declarações indicam que, já naquela época, havia a previsão de uma estrutura baseada em recursos compartilhados para o futuro. Desde meados da década de 1990, a sociedade passou a usufruir, de diferentes formas, aplicações compartilhadas via internet. Ferramentas de busca como Google, serviços de e-mail como Gmail, redes sociais e plataformas de publicação como Instagram, Facebook, YouTube, LinkedIn e Twitter tornaram-se parte integrante do cotidiano da maioria das pessoas.

Apesar da proximidade conceitual, o modelo de time-sharing ainda dependia de infraestruturas centralizadas e de alto custo. O acesso era restrito e a escalabilidade limitada pela capacidade física dos mainframes. Somente com a popularização das redes de computadores e da internet o ideal de computação como serviço começou a se tornar tecnicamente exequível e economicamente sustentável.

Nas décadas de 1980 e 1990, a consolidação da arquitetura cliente-servidor e o surgimento dos data centers corporativos estabeleceram as bases para o avanço do utility computing. As organizações passaram a concentrar seus sistemas em servidores de alto desempenho, enquanto os usuários acessavam os serviços por meio de estações conectadas em rede.

Com o aumento das demandas por processamento e armazenamento, ficou evidente que manter grandes infraestruturas dedicadas era caro e pouco eficiente. Muitos servidores operavam com níveis de utilização inferiores a 30% de sua capacidade total, e a ampliação da infraestrutura exigia investimentos constantes. Nesse cenário, a virtualização, conceito já presente desde os mainframes da IBM na década de 1970, ressurgiu como solução eficaz para otimizar o aproveitamento do hardware disponível.

A virtualização possibilitou a criação de múltiplos ambientes isolados em um único servidor físico, permitindo o provisionamento dinâmico de recursos. Essa flexibilidade abriu espaço para a consolidação do modelo de utility computing, no qual os recursos computacionais podem ser alocados, monitorados e tarifados de acordo com a demanda.

No início dos anos 2000, empresas como IBM, Sun Microsystems, HP e Oracle passaram a desenvolver iniciativas explicitamente associadas ao conceito de utility computing.

A IBM, por exemplo, destacou-se ao difundir o termo ao lançar, em 2001, a proposta de "e-business on demand", oferecendo infraestrutura e capacidade computacional sob demanda para organizações. A iniciativa buscava transformar a TI corporativa em um serviço mensurável, escalável e automatizado, princípios incorporados à computação em nuvem posteriormente.

De modo semelhante, a Sun Microsystems adotou o slogan "The Network is the Computer", defendendo que o processamento deveria ser distribuído e acessado por meio da rede, independentemente do hardware físico. Essa perspectiva contribuiu significativamente para o amadurecimento do paradigma de utility computing, reforçando a ideia de que o valor da computação está no serviço entregue, e não no equipamento em si.

Simultaneamente, os avanços em redes de alta velocidade, a padronização de protocolos como TCP/IP e a expansão acelerada da internet criaram condições favoráveis para modelos de negócios baseados em serviços computacionais remotos. O que antes era essencialmente conceitual passou a se concretizar na prática.

O impacto do utility computing é essencial para compreender a evolução da TI nas últimas décadas. Entre seus principais benefícios, destacam-se:

- **Redução de custos:** elimina grandes investimentos iniciais em infraestrutura própria.
- **Escalabilidade e elasticidade:** possibilita expandir ou reduzir recursos conforme a necessidade.
- **Pagamento sob demanda:** o uso é medido e cobrado de acordo com o consumo efetivo.
- **Automação e eficiência energética:** melhora o aproveitamento dos servidores e também reduz desperdícios.
- **Acesso universal:** amplia e democratiza o acesso aos recursos de TI.



Lembrete

Apesar de conceitos como time-sharing e utility computing existirem desde a década de 1960, somente com a difusão das redes de computadores e da internet é que o conceito de computação como serviço passou a ser tecnicamente possível e economicamente sustentável.

A consolidação do conceito de utility computing representa, assim, um ponto de inflexão na história da computação. Ele emergiu como resposta à busca por maior eficiência e flexibilidade na utilização de recursos tecnológicos e evoluiu, apoiado pela virtualização e pelo avanço das redes, até fundamentar a computação em nuvem contemporânea.

O que começou como uma ideia visionária de computação como serviço transformou-se em um modelo global de fornecimento de tecnologia. Atualmente, é difícil imaginar o funcionamento de empresas, governos e usuários finais sem recorrer, direta ou indiretamente, aos princípios estabelecidos pelo utility computing.

Mais do que uma tendência passageira, o utility computing consolidou uma nova abordagem para a TI, convertendo-a em um serviço estratégico, flexível e orientado à eficiência. Essa transformação abriu caminho não apenas para a computação em nuvem, mas também para paradigmas mais recentes, como fog computing e edge computing, que continuam a evoluir com base nos mesmos fundamentos.

1.2.5 Cloud computing

A passagem do conceito de utility computing para a computação em nuvem ocorreu de maneira gradual e coerente com a evolução tecnológica. O desenvolvimento da virtualização e a automação dos data centers possibilitaram que recursos computacionais fossem ofertados sob demanda, com escalabilidade e medição precisa do consumo, características que já constituíam os princípios centrais do utility computing.

A diferença fundamental é que, no contexto da nuvem, essa infraestrutura passou a ser disponibilizada como um serviço acessível via internet, estruturado em modelos claramente definidos, que serão abordados com mais profundidade no próximo capítulo. São eles: infraestrutura como serviço (infrastructure as a service – IaaS); plataforma como serviço (platform as a service – PaaS); e SaaS.

Esses modelos materializam o ideal da computação como utilidade ao fornecer recursos computacionais de forma semelhante aos serviços públicos, com elasticidade, automação e cobrança proporcional ao uso.

A computação em nuvem, conforme é compreendida atualmente, resulta de um processo histórico caracterizado por avanços tecnológicos progressivos e pela convergência de fatores econômicos, sociais e científicos. Embora propostas iniciais como time-sharing e utility computing tenham surgido ainda nos anos 1960, naquele período não existiam condições técnicas nem infraestrutura adequada para viabilizar sua adoção em larga escala. A computação dependia fortemente de grandes mainframes, sistemas proprietários e redes com capacidade bastante limitada.

Somente com o amadurecimento das redes de computadores e a disseminação global da internet é que a ideia de prover recursos computacionais como serviço passou a se tornar efetivamente realizável. A ampliação da conectividade, aliada à padronização de protocolos e à redução expressiva dos custos de hardware, criou o ambiente necessário para o surgimento da computação em nuvem tal como é conhecida hoje.

A partir dos anos 2000, o avanço das tecnologias de virtualização teve papel decisivo na transição dos conceitos teóricos para implementações práticas de computação em nuvem. Soluções como o VMware viabilizaram a criação de ambientes isolados, escaláveis e facilmente gerenciáveis sobre uma mesma infraestrutura física, aumentando a taxa de utilização dos recursos e reduzindo de forma significativa os custos operacionais dos data centers corporativos. Esse novo modelo ampliou a eficiência computacional

e tornou viáveis práticas como automação de ambientes, provisionamento sob demanda e elasticidade, elementos essenciais da nuvem moderna. Paralelamente, o fortalecimento das arquiteturas distribuídas e o desenvolvimento de sistemas de arquivos em larga escala, como o Google File System (GFS), estabeleceram as bases para o armazenamento distribuído capaz de sustentar aplicações globais com alta demanda.

O grande marco comercial para a popularização da computação em nuvem ocorreu em 2006, com o lançamento do Amazon Web Services (AWS). Serviços como o Amazon EC2 (Elastic Compute Cloud) permitiram que organizações de qualquer porte contratassem capacidade de processamento sob demanda, pagando exclusivamente pelo tempo de uso. Esse movimento representou a consolidação prática do conceito de computação utilitária dentro do paradigma da nuvem.

A Amazon, ao transformar sua experiência interna na operação de uma infraestrutura de grande escala voltada ao comércio eletrônico em um produto comercializável, passou a oferecer serviços de computação e armazenamento sob demanda. Com isso, estabeleceu oficialmente o modelo de IaaS. A partir desse momento, o mercado foi rapidamente impactado: pequenas empresas e startups passaram a ter acesso a recursos tecnológicos antes restritos a grandes corporações, sem a necessidade de investimentos elevados em hardware. Depois, empresas como Google e Microsoft fortaleceram esse movimento ao lançar o Google Cloud Platform (GCP) e o Microsoft Azure, ampliando as alternativas disponíveis ao mercado corporativo e introduzindo novas camadas de serviços, como PaaS e SaaS.



Observação

O Amazon EC2 foi um dos primeiros e mais influentes serviços de computação em nuvem, lançado pela AWS em 2006. Trata-se de um serviço de infraestrutura em nuvem que disponibiliza capacidade computacional sob demanda. O Amazon EC2 é uma plataforma que permite ao usuário criar e gerenciar instâncias de VMs com diferentes configurações de processamento, memória e armazenamento, de forma elástica e escalável. Esse modelo possibilita a execução de aplicações e serviços sem a necessidade de aquisição e manutenção de servidores físicos, seguindo o princípio da computação como serviço (Lopes; Souza Neto, 2015).

A difusão da computação em nuvem foi impulsionada não apenas por inovações tecnológicas, mas também por fatores econômicos relevantes. O modelo tradicional de aquisição de infraestrutura exigia altos investimentos iniciais (Capex), ciclos longos de planejamento e elevados custos de manutenção. Com a adoção da nuvem, esse cenário foi significativamente alterado. O modelo pay as you go, no qual o usuário paga apenas pelos recursos efetivamente consumidos, eliminou a necessidade de grandes desembolsos iniciais e possibilitou o crescimento dos ambientes de forma alinhada à demanda real. Essa flexibilidade permitiu que organizações experimentassem novas ideias, desenvolvessem protótipos rapidamente e competissem em mercados altamente dinâmicos, acelerando a adoção da nuvem em diversos setores.

Ao longo da década de 2010, a computação em nuvem expandiu-se de forma acelerada no contexto corporativo. Inicialmente restrita a empresas de tecnologia, passou a integrar a estratégia de organizações de grande porte em áreas como finanças, telecomunicações, saúde e setor público. A ampla oferta de serviços gerenciados como bancos de dados, mensageria, análise de dados e IA, reduziu consideravelmente a complexidade operacional e permitiu que equipes de TI direcionassem esforços para inovação em vez de manutenção. Nesse período, consolidou-se também a abordagem cloud-first, na qual novas soluções são projetadas para operar prioritariamente na nuvem. Em seguida, ganhou destaque o conceito de cloud-native, que engloba práticas como microsserviços, pipelines de CI/CD, contêineres e orquestração com Kubernetes.

A popularização da nuvem ultrapassou o ambiente corporativo e passou a impactar diretamente o cotidiano dos usuários finais. Serviços amplamente utilizados, como Google Drive, Dropbox, OneDrive e iCloud, familiarizaram milhões de pessoas com o armazenamento remoto e a sincronização automática de dados. De forma semelhante, plataformas de streaming como Netflix e Spotify dependem fortemente de infraestrutura em nuvem para distribuir conteúdo de maneira eficiente em escala global. Além disso, softwares tradicionalmente instalados localmente migraram para o modelo de serviços acessados via navegador, como Google Docs e Office 365. A difusão dos smartphones intensificou ainda mais essa integração, tornando a nuvem um componente invisível, porém essencial, da maioria dos serviços digitais utilizados diariamente.

Com o amadurecimento da computação em nuvem, formou-se um ecossistema robusto que impulsionou novas práticas de desenvolvimento e operação. O movimento DevOps, por exemplo, foi fortalecido pelo uso da automação e da padronização oferecidas pelas plataformas em nuvem, criando maior integração entre desenvolvimento e infraestrutura. O uso de contêineres e de ferramentas de orquestração, como Kubernetes, transformou a forma de empacotar, distribuir e escalar aplicações. Mais recentemente, o modelo serverless introduziu um nível adicional de abstração, permitindo a execução de funções sob demanda sem a necessidade de gerenciamento direto de servidores. Paralelamente, o crescimento da IoT e da computação de borda (edge computing) ampliou o alcance da nuvem para além dos data centers centrais, atendendo aplicações distribuídas e sensíveis à latência.

A rápida expansão da computação em nuvem também trouxe desafios relevantes. Questões relacionadas à segurança da informação, privacidade e soberania dos dados tornaram-se centrais, especialmente em contextos que envolvem informações sensíveis ou regulamentadas. Surgiram ainda preocupações quanto à dependência excessiva de um único provedor e à imprevisibilidade dos custos decorrentes do consumo variável de recursos. A necessidade de conformidade com legislações como o General Data Protection Regulation (GDPR) e a LGPD reforçou essas preocupações em operações globais. Como resposta, ganharam destaque arquiteturas híbridas e multicloud, que combinam diferentes provedores e ambientes locais para equilibrar flexibilidade, segurança e controle financeiro.

Apesar desses desafios, a computação em nuvem consolidou-se como o principal modelo de provisão de serviços de TI. Sua adoção deixou de ser vista como uma tendência emergente e passou a integrar de forma definitiva a infraestrutura digital contemporânea. A combinação de avanços em hardware, redes, virtualização, modelos econômicos inovadores e a atuação estratégica de grandes provedores permitiu que a nuvem atingisse escala global em poucas décadas. Atualmente, ela sustenta

serviços essenciais, que vão desde sistemas financeiros até redes sociais, além de viabilizar inovações em áreas como IA, computação quântica e análise de grandes volumes de dados.

Dessa forma, a disseminação da computação em nuvem representa uma mudança histórica na forma como a tecnologia é consumida, desenvolvida e distribuída. Ela ampliou o acesso à infraestrutura computacional, reduziu barreiras à inovação, fomentou novos modelos de negócio e redefiniu a relação entre pessoas, organizações e tecnologia. A nuvem tornou-se uma infraestrutura invisível que sustenta grande parte da economia digital contemporânea, marcando um dos capítulos mais relevantes da evolução da computação moderna.

1.2.6 Fog computing

Observamos que a computação em nuvem modificou significativamente a maneira como empresas, organizações e indivíduos armazenam, processam e acessam informações. Desde a sua consolidação, esse modelo passou a oferecer maior flexibilidade, escalabilidade e otimização de custos, possibilitando o desenvolvimento de aplicações inovadoras e impulsionando a transformação digital em diversos setores. Entretanto, com o crescimento acelerado da quantidade de dispositivos conectados à internet, passaram a surgir novos desafios relacionados à latência, segurança, largura de banda e privacidade dos dados.

O destaque da computação em nuvem tornou-se mais evidente a partir da década de 2000, quando provedores como AWS, Google Cloud e Microsoft Azure passaram a disponibilizar recursos de armazenamento, processamento e diversos serviços de forma remota. Esse modelo permitiu que organizações de diferentes portes utilizassem recursos computacionais sob demanda, reduzindo ou eliminando a necessidade de grandes investimentos em infraestrutura própria.

Nos estágios iniciais de sua adoção, a computação em nuvem foi amplamente compreendida como uma arquitetura centralizada, na qual os dados eram enviados para data centers remotos para serem processados. Esse modelo mostrou-se adequado para diversas aplicações, sobretudo aquelas que não demandavam respostas imediatas. Contudo, com a expansão da IoT, de veículos conectados, sistemas de monitoramento por vídeo e outros dispositivos inteligentes, o volume de dados gerados passou a crescer de forma significativa e a se distribuir geograficamente.

Apesar das inúmeras vantagens oferecidas pela computação em nuvem, algumas limitações tornam-se evidentes, principalmente em cenários que exigem baixa latência, alta confiabilidade e processamento em tempo real. Entre essas limitações, destacam-se:

- **Latência:** o tempo necessário para transmitir os dados até o data center e retornar com a resposta pode ser elevado, o que impacta aplicações sensíveis ao tempo, como veículos autônomos ou sistemas de monitoramento na área da saúde.
- **Largura de banda:** o grande volume de dados transmitidos pela rede pode gerar sobrecarga, elevando custos e dificultando a escalabilidade do sistema.
- **Privacidade e segurança:** informações sensíveis podem estar mais expostas a riscos durante o processo de transmissão ou armazenamento em ambientes remotos.

- **Dependência de conexão:** o funcionamento adequado depende de conectividade constante, o que pode representar um problema em regiões com infraestrutura de rede limitada ou instável.

Diante dessas limitações, surgiu a necessidade de desenvolver arquiteturas capazes de realizar o processamento de dados mais próximo das fontes que os geram, buscando minimizar problemas relacionados à latência, ao volume de dados, à privacidade e à conectividade.

Nesse contexto, abordagens como fog computing e edge computing passaram a ser consideradas extensões ou evoluções naturais da computação em nuvem, ao deslocar parte do processamento para regiões mais próximas dos dispositivos que produzem os dados.

O fog computing, também chamado de computação em névoa ou nuvem de borda, corresponde a uma arquitetura que amplia os recursos de computação, armazenamento e rede em direção à borda da infraestrutura. Dessa forma, os serviços passam a operar mais próximos dos dispositivos finais. Essa estratégia tem como objetivo reduzir a latência, aumentar a eficiência do processamento e proporcionar maior segurança, ao permitir que parte dos dados seja processada localmente antes de ser encaminhada para a nuvem central (Bonomi *et al.*, 2012).

Nesse modelo, o fog computing atua como uma extensão da computação em nuvem, distribuindo capacidades de processamento, armazenamento e comunicação para regiões mais próximas da borda da rede. O princípio fundamental consiste em estabelecer uma camada intermediária entre os dispositivos finais e os data centers, formada por nós de processamento distribuídos, como roteadores, gateways e servidores locais.

A figura apresentada a seguir demonstra o conceito de fog computing como uma extensão da computação em nuvem para uma camada intermediária posicionada próxima aos dispositivos finais.




Figura 5 – Fog computing

Adaptada de: <https://tinyurl.com/2tm9k32e>. Acesso em: 19 maio 2025.

O fog computing é especialmente útil em aplicações de IoT, cidades inteligentes, manufatura 4.0, saúde e automotivo, em que a resposta rápida e a privacidade são essenciais. Por exemplo, em veículos autônomos, o processamento de dados de sensores deve ocorrer em tempo real para garantir a segurança, o que torna o fog uma solução ideal.

As principais características do fog computing são:

- **Proximidade aos dispositivos finais:** os recursos estão localizados próximos às fontes de dados, reduzindo a latência.
- **Distribuição:** os nós de fog podem estar espalhados geograficamente, formando uma rede de processamento descentralizada.
- **Capacidade de processamento local:** permite executar tarefas de análise, filtragem e decisão em tempo real, sem depender da nuvem central.
- **Segurança aprimorada:** dados sensíveis podem ser processados localmente, minimizando riscos durante a transmissão.



Saiba mais

Um dos trabalhos pioneiros em fog computing é o artigo de Bonomi *et al.* (2012), que é bastante citado na pesquisa científica sobre IoT, edge e sistemas distribuídos. Para saber mais, leia o artigo:

BONOMI, F. *et al.* Fog computing and its role in the internet of things. In: WORKSHOP ON MOBILE CLOUD COMPUTING, 1., 2012, Helsinki. *Proceedings* [...]. New York: ACM, 2012. p. 13-16. Disponível em: <https://tinyurl.com/zym5emp3>. Acesso em: 20 maio 2026.

1.2.7 Edge computing

Com o avanço da IoT, da indústria 4.0 e das redes 5G, surgiu a necessidade de processar dados ainda mais próximos de onde eles são gerados. Nesse contexto, destaca-se o edge computing, ou computação na borda. Enquanto o fog computing representa uma arquitetura mais distribuída, o edge computing se refere ao processamento de dados realizado diretamente nos dispositivos finais ou em pontos próximos a eles.

O termo "edge", que significa "borda", refere-se justamente à extremidade da rede, onde estão localizados sensores, dispositivos IoT, câmeras e outros equipamentos conectados. Nesse modelo, esses dispositivos ou infraestruturas próximas a eles passam a executar tarefas de processamento, análise ou filtragem de dados, reduzindo a necessidade de enviar todas as informações diretamente para a nuvem.

Embora apresente semelhanças com o conceito de fog computing, que também propõe descentralizar o processamento, o edge computing concentra-se especificamente no processamento realizado nos pontos mais próximos dos dispositivos finais. O conceito ganhou maior visibilidade entre os anos de 2014 e 2016, impulsionado principalmente pela expansão de aplicações conectadas e pela necessidade de respostas em tempo real em diversos setores tecnológicos.

De forma geral, o edge computing pode ser definido como uma arquitetura em que o processamento de dados ocorre próximo à sua fonte de geração, como sensores, equipamentos industriais ou dispositivos inteligentes. Essa abordagem busca diminuir a latência, reduzir o consumo de largura de banda da rede e permitir respostas mais rápidas em aplicações críticas, como veículos autônomos, monitoramento de saúde e sistemas industriais inteligentes (Shi *et al.*, 2016).

A figura a seguir apresenta uma representação dessa arquitetura. Na parte inferior, encontram-se dispositivos IoT conectados a antenas ou gateways, que formam a camada inicial de comunicação da rede. Em seguida aparece a camada de edge, composta por nós de borda equipados com capacidade de processamento e armazenamento local. Esses nós são responsáveis por executar tarefas como análise de dados, filtragem de informações, gerenciamento de dispositivos IoT, entrega de serviços e armazenamento em cache diretamente na borda da rede.




Figura 6 – Edge computing

Disponível em: <https://tinyurl.com/ypdet2fw>. Acesso em: 20 maio 2026.

Além disso, esses nós podem se comunicar e cooperar entre si, característica que reforça o caráter distribuído dessa arquitetura. Após esse processamento inicial, apenas os dados necessários ou já tratados são enviados para a nuvem, localizada na camada superior do modelo, onde se encontram recursos de

grande capacidade de processamento e armazenamento em larga escala. Dessa forma, o edge computing permite aproximar os recursos computacionais dos usuários e dispositivos, contribuindo para a redução da latência, do tráfego na rede e da dependência exclusiva da infraestrutura de cloud computing.

São vários os benefícios do edge computing. Entre eles estão:

- **Baixa latência:** processamento quase instantâneo, fundamental para aplicações críticas.
- **Redução de banda:** dados relevantes são processados localmente, enviando apenas informações essenciais para a nuvem.
- **Privacidade:** dados sensíveis permanecem no dispositivo ou na rede local.
- **Resiliência:** operações continuam mesmo em caso de conexão instável com a nuvem.

A expansão da IoT, aliada à popularização dos serviços de computação em nuvem, favoreceu o surgimento do edge computing que possibilita atender aplicações que exigem respostas rápidas, além de contribuir para a redução do consumo de energia dos dispositivos, diminuir os custos relacionados ao uso de banda de rede e reforçar aspectos de segurança e privacidade das informações.

Apesar de fog computing e edge computing estarem fortemente relacionados e muitas vezes atuarem de forma conjunta, eles não representam exatamente o mesmo conceito. Ambos surgem com o objetivo de aproximar o processamento computacional da origem dos dados, diminuindo a latência da comunicação, reduzindo o tráfego de rede e aumentando a eficiência de aplicações distribuídas. No entanto, cada abordagem apresenta diferenças em relação à arquitetura adotada, ao alcance da infraestrutura e ao tipo de processamento que realizam.

O edge computing está diretamente associado ao processamento realizado muito próximo dos dispositivos que produzem os dados ou até mesmo dentro desses próprios dispositivos. Sensores, câmeras inteligentes, smartphones, roteadores ou equipamentos IoT são exemplos de elementos que podem executar tarefas de análise ou decisão localmente. Como esses dispositivos geralmente possuem recursos computacionais limitados, o modelo é especialmente adequado para aplicações que necessitam de respostas imediatas e processamento em tempo real, como sistemas de autenticação por reconhecimento facial, monitoramento contínuo de pacientes ou controle automatizado de equipamentos conectados.

Por outro lado, o fog computing apresenta uma proposta arquitetural mais abrangente. Nesse modelo, existe uma camada intermediária de processamento posicionada entre os dispositivos finais e a infraestrutura de nuvem. Essa camada é formada por diversos nós distribuídos, que podem incluir gateways avançados, servidores locais ou pequenos centros de dados próximos à borda da rede. Esses recursos oferecem maior capacidade de processamento e armazenamento quando comparados aos dispositivos de edge, permitindo executar tarefas mais complexas, realizar análises de dados mais elaboradas e coordenar o funcionamento de múltiplos dispositivos conectados.

Dessa forma, enquanto o edge computing prioriza o processamento local e imediato nos próprios dispositivos ou em seus arredores, o fog computing organiza uma infraestrutura distribuída capaz de oferecer suporte a cargas de trabalho mais pesadas e a ambientes de maior escala. Em muitos cenários, as duas abordagens atuam de maneira complementar, contribuindo para melhorar o desempenho e a eficiência dos sistemas.

A evolução da computação em nuvem para modelos como fog e edge computing reflete a necessidade de superar as limitações de arquiteturas totalmente centralizadas. O crescimento acelerado do número de dispositivos conectados e a demanda por processamento quase instantâneo impulsionaram o desenvolvimento dessas soluções distribuídas. Como resultado, torna-se possível enfrentar desafios relacionados à latência, ao consumo de largura de banda, à segurança e à privacidade das informações.

Com o avanço das tecnologias digitais, a tendência é que a integração entre cloud, fog e edge computing se torne cada vez mais presente. Essa combinação permitirá a construção de infraestruturas computacionais mais distribuídas, eficientes e escaláveis, fundamentais para o desenvolvimento de aplicações modernas como cidades inteligentes, veículos autônomos, sistemas de saúde digital e outras soluções que dependem do processamento rápido e contínuo de grandes volumes de dados.



Lembrete

Diferença entre fog computing e edge computing:

- **Fog computing:** arquitetura em vários níveis, com nós intermediários entre a nuvem e os dispositivos.
- **Edge computing:** processamento na ponta, quase sempre no dispositivo ou no gateway mais próximo.

1.3 Expansão e adoção da computação em nuvem

No início, a computação em nuvem foi adotada com certa cautela pelas empresas, principalmente devido a preocupações relacionadas à segurança dos dados e à dependência de conexões com a internet. Com o passar do tempo, entretanto, esse modelo evoluiu e se consolidou como um paradigma tecnológico robusto, capaz de suportar desde aplicações essenciais até operações de grande escala em diversos setores. Essa transformação não ocorreu apenas em função dos avanços tecnológicos, mas também da crescente necessidade das organizações de se tornarem mais ágeis, competitivas e orientadas por dados em um contexto de constante transformação digital.

À medida que a maturidade da computação em nuvem aumentou, também evoluíram os mecanismos de segurança, governança e confiabilidade dos serviços oferecidos. Provedores passaram a investir fortemente em certificações, criptografia avançada, redundância geográfica e alta disponibilidade, elevando o nível de confiança das organizações nesse modelo. Paralelamente, surgiram

novas arquiteturas e práticas, como microsserviços, contêineres e automação de infraestrutura, que potencializaram ainda mais o uso da nuvem. Esse conjunto de avanços contribuiu para que a computação em nuvem deixasse de ser vista apenas como uma alternativa tecnológica e passasse a ser considerada uma base estratégica para a transformação digital.

Esse modelo mais flexível e dinâmico permite que as organizações aproveitem melhor o potencial da tecnologia para expandir suas operações, ao mesmo tempo que reduzem custos operacionais e simplificam a gestão e a manutenção de infraestrutura física. Nesse sentido, a adoção da computação em nuvem representa uma mudança estratégica importante, pois desloca o foco da administração de equipamentos e recursos de hardware para iniciativas voltadas à inovação e ao desenvolvimento de novos negócios.

Entre os impactos mais evidentes da computação em nuvem nas empresas está a substituição do modelo tradicional de infraestrutura por um que seja baseado em serviços. Antes da popularização da nuvem, as organizações precisavam realizar investimentos elevados em servidores físicos, sistemas de armazenamento, redes e equipes especializadas responsáveis pela manutenção e atualização desses recursos. Esse cenário implicava altos custos iniciais e longos períodos de planejamento e implementação. Com a computação em nuvem, a infraestrutura passou a ser disponibilizada sob demanda, permitindo que as empresas utilizem apenas os recursos necessários e ampliem sua capacidade de forma rápida sempre que houver necessidade. Essa elasticidade contribui para a redução de desperdícios, melhora a eficiência operacional e possibilita respostas mais rápidas às mudanças do mercado.

A figura a seguir evidencia alguns marcos importantes que contribuíram para a evolução da computação em nuvem e para sua ampla adoção no cenário tecnológico atual.




Figura 7 – Expansão da computação em nuvem

Adaptada de: The cloud... (2022).

O primeiro avanço importante dentro dessa evolução ocorreu em 1999, quando a empresa VMware lançou o software VMware Workstation. Essa tecnologia permitiu executar múltiplas VMs em um único computador físico, facilitando o provisionamento de ambientes virtuais. A virtualização tornou-se um elemento fundamental para a computação em nuvem, pois possibilitou o melhor aproveitamento dos recursos de hardware e a criação de infraestruturas mais flexíveis e escaláveis.

Alguns anos depois, em 2006, a Amazon lançou o serviço Amazon EC2 dentro da plataforma AWS. Esse serviço marcou o início da oferta de infraestrutura computacional sob demanda pela internet, permitindo que empresas alugassem capacidade de processamento e armazenamento conforme a necessidade, em vez de manterem seus próprios data centers.

Em 2007, a Apple apresentou o iPhone, que revolucionou o mercado de dispositivos móveis. A popularização dos smartphones ampliou significativamente o número de usuários conectados e de aplicações online, aumentando a demanda por serviços hospedados na nuvem para armazenamento, processamento e sincronização de dados.

No ano seguinte, 2008, a Google lançou o Google App Engine, uma plataforma que permitia aos desenvolvedores criar e executar aplicações diretamente na infraestrutura da empresa. Esse modelo consolidou o conceito de PaaS, simplificando o desenvolvimento e a implantação de aplicações web escaláveis.

Em 2010, a Microsoft passou a oferecer sua própria plataforma de nuvem, o Microsoft Azure; assim, ampliou a concorrência entre provedores e contribuiu para a expansão do mercado de serviços em nuvem.

Outro marco importante ocorreu em 2013, quando o Docker disponibilizou sua tecnologia de contêineres como software de código aberto. Os contêineres facilitaram a criação, distribuição e execução de aplicações em diferentes ambientes, tornando-se uma tecnologia central para arquiteturas modernas baseadas em microsserviços e computação em nuvem.

Já em 2020, a pandemia de covid-19 acelerou ainda mais a transformação digital em todo o mundo. As medidas de distanciamento social impulsionaram o trabalho remoto, a educação a distância e o uso intensivo de plataformas digitais, incentivando práticas de colaboração remota, mobilidade corporativa e a integração de equipes distribuídas globalmente. Esse movimento acelerou a adoção de soluções baseadas em nuvem, inclusive em organizações que anteriormente demonstravam resistência (Rapôso; Costa Junior; Ferreira, 2024). Como consequência, muitas empresas passaram a adotar modelos híbridos de trabalho, sustentados por plataformas em nuvem que possibilitam a continuidade das operações, alta disponibilidade dos sistemas e colaboração em tempo real. Com aplicações e dados acessíveis a partir de qualquer local com conexão à internet, os colaboradores passaram a executar suas atividades de maneira descentralizada, utilizando ferramentas compartilhadas para comunicação, armazenamento de informações e desenvolvimento de tarefas.

Por fim, projeções indicavam que, em 2024, o mercado global de computação em nuvem continuaria em forte crescimento, com estimativas de que o valor do setor ultrapassaria US\$ 429 bilhões. Esse cenário evidencia como a nuvem se consolidou como uma infraestrutura essencial para suportar aplicações modernas, serviços digitais e novas tecnologias emergentes (The cloud..., 2022).

Assim, a sequência de eventos apresentada demonstra que a computação em nuvem não surgiu de forma repentina, mas sim como resultado de diversos avanços tecnológicos que ocorreram ao longo do tempo, incluindo virtualização, dispositivos móveis, plataformas de desenvolvimento, contêineres e a crescente necessidade de infraestrutura escalável para suportar a transformação digital.

Outro elemento importante para a popularização da nuvem foi o estabelecimento de grandes provedores de serviços especializados, como plataformas de infraestrutura, desenvolvimento e aplicações disponibilizadas pela internet. Esses provedores passaram a oferecer soluções completas de armazenamento, processamento e gerenciamento de dados, simplificando a implantação de sistemas e reduzindo a necessidade de investimentos iniciais em hardware e manutenção.

Tal avanço por parte dos provedores fomentou a inovação e o ganho de velocidade no desenvolvimento de soluções tecnológicas. Assim, as plataformas de computação em nuvem disponibilizam uma ampla variedade de ferramentas avançadas que antes estavam restritas a grandes organizações, como serviços de IA, aprendizado de máquina, computação de alto desempenho, bancos de dados escaláveis e ambientes integrados de desenvolvimento. Ao reduzir barreiras tecnológicas e financeiras, a nuvem amplia o acesso a esses recursos e permite que empresas de diferentes portes desenvolvam novos produtos, testem ideias de maneira ágil e lancem soluções no mercado em prazos menores. Como resultado, o ambiente empresarial torna-se mais competitivo e passa a incentivar práticas como experimentação contínua, desenvolvimento de protótipos rápidos e tomada de decisões baseada em dados e indicadores.

Como resultado, vemos que a computação em nuvem desempenha um papel fundamental na transformação digital das organizações. Tecnologias emergentes, como big data, IA, IoT e aprendizado de máquina, dependem fortemente de ambientes escaláveis e de alta capacidade de processamento, características que são facilmente atendidas pelas plataformas de nuvem.

A adoção da computação em nuvem tem se expandido em diversos setores, incluindo indústria, saúde, educação, comércio eletrônico e serviços financeiros. Esse crescimento consolidou a nuvem como uma infraestrutura essencial para aplicações modernas, possibilitando o desenvolvimento de soluções mais ágeis, inovadoras e acessíveis em escala global.

1.4 Principais características da computação em nuvem

O National Institute of Standards and Technology (NIST) publicou, em 2011, o documento intitulado "The NIST Definition of Cloud Computing", identificado como Special Publication 800-145. Esse material apresenta uma definição amplamente utilizada para computação em nuvem, além de descrever seus principais elementos, que servem como referência para compreender, comparar e analisar diferentes serviços e estratégias de adoção da nuvem (Mell; Grance, 2011).

De acordo com o NIST (Mell; Grance, 2011), a computação em nuvem é estruturada a partir de cinco características essenciais, três modelos de serviço e quatro modelos de implantação. A figura 8 reúne esses componentes, que serão abordados e discutidos ao longo desta unidade.




Figura 8 – Características e modelos da computação em nuvem
(imagem produzida com a ferramenta de IA generativa ChatGPT, da OpenAI)

Adaptada de: Mell e Grance (2011).

Os modelos de serviço e de implantação descritos no documento constituem uma taxonomia simplificada, cuja finalidade não é determinar ou limitar formas específicas de implementação, oferta de serviços ou operação de negócios. Ainda assim, essas definições passaram a ser amplamente adotadas como referência internacional para a compreensão da computação em nuvem.

Dessa forma, a computação em nuvem pode ser entendida como um modelo de computação que permite acesso amplo, conveniente e sob demanda, por meio da rede, a um conjunto compartilhado de recursos configuráveis como redes, servidores, armazenamento, aplicações e serviços. Esses recursos podem ser provisionados e liberados rapidamente, com pouco esforço de gerenciamento e mínima interação com o provedor do serviço.

Ao fazermos um recorte na figura anterior, focando especificamente na porção que descreve as cinco características essenciais da computação em nuvem, obtemos a figura a seguir.




Figura 9 – Características essenciais de computação em nuvem

Adaptada de: Mell e Grance (2011).

As cinco características essenciais da computação em nuvem, que veremos com mais detalhes nas próximas seções, são: amplo acesso à rede; rápida elasticidade; serviços medidos; self service sob demanda; e pool de recursos.

1.4.1 Amplo acesso à rede

Refere-se à capacidade da computação em nuvem de disponibilizar recursos e serviços por meio de redes de comunicação, geralmente pela internet, utilizando mecanismos e protocolos padronizados. Essa característica possibilita que aplicações, plataformas e dados armazenados na nuvem sejam acessados a partir de diferentes tipos de dispositivos, como computadores pessoais, smartphones, tablets, notebooks e estações de trabalho.

Tal acesso pode ocorrer independentemente do sistema operacional utilizado ou da localização geográfica do usuário, desde que exista conectividade com a rede. Dessa forma, a computação em nuvem reduz as limitações físicas que tradicionalmente estavam presentes nos ambientes de TI, ampliando significativamente as possibilidades de acesso e uso de recursos computacionais.

Nos modelos tradicionais de infraestrutura de TI, os sistemas e dados geralmente ficavam restritos ao ambiente interno das organizações, sendo acessados principalmente a partir de equipamentos conectados à rede local. Esse modelo limitava a mobilidade dos usuários e dificultava o compartilhamento de informações fora do ambiente corporativo. Com a adoção da computação em nuvem e do amplo acesso à rede, essas barreiras foram gradualmente reduzidas. Usuários podem acessar aplicações e dados hospedados em provedores de nuvem a partir de praticamente qualquer lugar, utilizando diferentes dispositivos conectados à internet. Esse cenário contribui para tornar os sistemas mais acessíveis e flexíveis, acompanhando as necessidades de um mundo cada vez mais conectado e digital.

A figura 10 ilustra o conceito de amplo acesso à rede, em que serviços e recursos disponibilizados na nuvem podem ser acessados por meio da internet utilizando diferentes dispositivos, como computadores pessoais, laptops, smartphones e outros equipamentos conectados à rede. Essa característica permite que usuários utilizem aplicações e dados de forma remota, independentemente da localização ou do dispositivo utilizado, desde que possuam acesso à rede.




Figura 10 – Amplo acesso à rede na computação em nuvem

Do ponto de vista organizacional, o amplo acesso à rede traz impactos significativos na forma como empresas e instituições utilizam a tecnologia. Uma das principais vantagens está relacionada à mobilidade, permitindo que colaboradores acessem sistemas corporativos, documentos e aplicações independentemente de estarem fisicamente presentes no ambiente da empresa. Isso favorece modelos de trabalho remoto, home office e equipes distribuídas geograficamente, que se tornaram cada vez mais comuns em diversos setores. Além disso, essa característica facilita a colaboração entre profissionais, uma vez que diferentes usuários podem acessar e compartilhar informações em tempo real por meio de plataformas baseadas em nuvem.

Outro aspecto relevante é a continuidade dos negócios. Como os serviços em nuvem podem ser acessados remotamente, organizações conseguem manter suas operações mesmo em situações em que o acesso físico às instalações é limitado ou interrompido. Dessa forma, sistemas críticos e dados importantes permanecem disponíveis para os usuários autorizados, desde que exista acesso à rede. Essa capacidade aumenta a resiliência das operações e contribui para a manutenção da produtividade em diferentes cenários.

O amplo acesso à rede favorece a utilização de aplicações baseadas em navegadores, chamadas de aplicações web. Nesse modelo, grande parte do processamento e do armazenamento ocorre nos servidores do provedor de nuvem, enquanto o usuário interage com o sistema por meio de um navegador ou de um aplicativo leve. Essa abordagem reduz a necessidade de instalação de softwares complexos nos dispositivos dos usuários, além de simplificar processos de atualização e manutenção, já que as modificações podem ser realizadas diretamente no ambiente do provedor de serviços.

Sob a perspectiva técnica, essa característica está associada ao uso de protocolos de comunicação abertos e amplamente adotados, como HTTP, HTTPS, TCP/IP e APIs baseadas em REST. Esses padrões garantem que diferentes sistemas, dispositivos e plataformas possam se comunicar de forma eficiente, promovendo interoperabilidade entre tecnologias distintas. A padronização também contribui para a escalabilidade das soluções em nuvem, permitindo que um grande número de usuários acesse os serviços simultaneamente sem comprometer o desempenho.

Além disso, provedores de computação em nuvem projetam suas infraestruturas para suportar grandes volumes de acesso, utilizando técnicas de balanceamento de carga, distribuição geográfica de servidores e redes de entrega de conteúdo (CDNs, do inglês, content delivery networks). Esses mecanismos ajudam a garantir que os serviços permaneçam disponíveis e com bom desempenho, mesmo diante de um número elevado de requisições provenientes de diferentes regiões.

Portanto, o amplo acesso à rede desempenha um papel fundamental no modelo de computação em nuvem, pois permite que recursos computacionais sejam utilizados de forma flexível, acessível e distribuída. Essa característica não apenas facilita o acesso aos serviços, como também contribui para a transformação digital das organizações, possibilitando novas formas de trabalho e utilização da tecnologia em diferentes contextos. A computação em nuvem amplia a disponibilidade dos serviços, favorecendo mobilidade, colaboração e acesso contínuo às informações. Dessa maneira, o amplo acesso à rede se consolida como um dos pilares que sustentam a expansão e a adoção da computação em nuvem em escala global.

1.4.2 Rápida elasticidade

A elasticidade é considerada uma das propriedades centrais da computação em nuvem e está relacionada à capacidade de adaptar dinamicamente a quantidade de recursos computacionais conforme a variação da demanda. Em outras palavras, os recursos podem ser ampliados ou reduzidos de maneira flexível, permitindo que sistemas e aplicações utilizem apenas a capacidade necessária em cada momento.

Nos modelos tradicionais de infraestrutura de TI, a expansão de recursos costuma exigir a aquisição de equipamentos físicos, como servidores, dispositivos de armazenamento e componentes de rede. Esse processo geralmente envolve etapas administrativas e logísticas que podem levar semanas ou até meses, tornando a adaptação da infraestrutura lenta e pouco flexível. Além disso, os equipamentos precisam ser instalados em um espaço físico adequado, frequentemente em salas ou data centers preparados com sistemas de energia, refrigeração e segurança. Também é necessário garantir que os novos recursos sejam compatíveis com a arquitetura tecnológica existente e com os sistemas utilizados pela organização. Após a implantação, a empresa ainda precisa contar com profissionais especializados para administrar e manter todo o ambiente em funcionamento.

Esse modelo tradicional apresenta limitações quando ocorre crescimento na demanda ou expansão das atividades da organização. A infraestrutura local tende a ser dimensionada para suportar uma determinada carga de trabalho, o que dificulta ajustes rápidos em cenários de aumento inesperado de uso. Para evitar indisponibilidades, muitas empresas acabam adquirindo mais recursos do que realmente utilizam, planejando a infraestrutura para suportar picos de acesso que nem sempre se concretizam. Como consequência, parte dos equipamentos permanece ociosa durante longos períodos, gerando custos desnecessários de aquisição, manutenção e energia.

A computação em nuvem surge como uma alternativa para superar essas limitações, oferecendo recursos de computação disponibilizados como serviços escaláveis e acessíveis sob demanda. Nesse modelo, provedores de nuvem mantêm grandes infraestruturas de data centers e disponibilizam capacidade computacional para diferentes clientes de forma compartilhada e virtualizada. Assim, organizações podem aumentar ou reduzir rapidamente a quantidade de recursos utilizados, sem a necessidade de adquirir ou instalar novos equipamentos físicos.

Em ambientes elásticos, recursos como processamento, armazenamento e largura de banda podem ser ajustados de maneira ágil e, muitas vezes, automática. Essa flexibilidade contrasta com a infraestrutura tradicional instalada localmente (on-premises), na qual a capacidade disponível permanece relativamente fixa, independentemente das variações no uso ao longo do tempo. Na nuvem, os recursos podem ser provisionados ou liberados conforme a necessidade, permitindo que aplicações mantenham desempenho adequado mesmo diante de mudanças significativas na carga de trabalho.

De acordo com o modelo de computação em nuvem, a capacidade disponível para os usuários pode ser provisionada e liberada elasticamente, muitas vezes por meio de mecanismos automatizados. Dessa forma, os recursos podem ser ampliados rapidamente quando ocorre aumento de demanda e reduzidos quando o volume de utilização diminui. Para quem utiliza os serviços, essa infraestrutura pode

aparentar ser praticamente ilimitada, já que novos recursos podem ser disponibilizados em diferentes quantidades e em poucos instantes.

Sob a perspectiva operacional, a elasticidade permite que sistemas reajam de forma automática a variações de carga, como períodos de maior acesso, campanhas promocionais, lançamentos de produtos ou eventos inesperados. Ferramentas e mecanismos como auto scaling e balanceamento de carga permitem monitorar métricas de uso e, com base nelas, criar ou remover instâncias de recursos computacionais. Esse processo ajuda a manter níveis adequados de desempenho, disponibilidade e estabilidade das aplicações, evitando sobrecarga de servidores durante momentos de alto tráfego.

Além dos ganhos técnicos, a elasticidade traz impactos importantes no aspecto econômico e estratégico das organizações. Como os recursos podem ser utilizados sob demanda e liberados quando não são mais necessários, as empresas passam a pagar apenas pela capacidade efetivamente utilizada. Esse modelo reduz desperdícios e evita investimentos elevados em infraestrutura própria que poderia ficar subutilizada. Ao mesmo tempo, essa flexibilidade incentiva a experimentação e a inovação, pois novas aplicações e serviços podem ser testados rapidamente sem a necessidade de grandes investimentos iniciais em hardware.

Assim, a elasticidade representa um dos principais diferenciais da computação em nuvem, permitindo que as organizações alinhem a capacidade de processamento e armazenamento às necessidades reais de suas operações. Esse ajuste dinâmico de recursos contribui para melhorar o desempenho das aplicações, otimizar custos e oferecer maior agilidade na adaptação a mudanças no ambiente de negócios e nas demandas dos usuários.

1.4.3 Serviços medidos

Outra característica relevante da computação em nuvem, considerada também uma de suas principais vantagens, é o modelo de pagamento baseado no consumo (pay per use), no qual o cliente paga somente pelos recursos que realmente utiliza. Nesse contexto, elementos como capacidade de processamento, espaço de armazenamento, volume de transferência de dados e quantidade de acessos são constantemente monitorados e registrados pelo provedor de serviços em nuvem. A partir dessas medições, a cobrança é realizada de acordo com o consumo efetivo, de maneira semelhante ao que ocorre com serviços públicos, como fornecimento de energia elétrica ou água.



Observação

"Pay as you go", "pay as you use" e "pay per use" são termos usados para descrever o mesmo modelo de cobrança: pagamento pelo uso real. Ou seja, são termos utilizados de forma intercambiável para dizer a mesma coisa: "não temos mensalidade fixa; se você não usar os nossos serviços, não paga".

Embora esse modelo de cobrança esteja relacionado a outras características da computação em nuvem como o autosserviço sob demanda, que permite ao usuário solicitar recursos quando necessário,

e a elasticidade, que possibilita ajustar rapidamente a capacidade disponível, o conceito de pagamento pelo uso está diretamente ligado à característica conhecida como serviços mensurados, conforme descrito pelo NIST (Mell; Grance, 2011).

Nos ambientes de computação em nuvem, o uso de recursos é acompanhado e otimizado automaticamente por meio de mecanismos de medição que operam em diferentes níveis de abstração, dependendo do tipo de serviço oferecido. Dessa forma, aspectos como utilização de armazenamento, tempo de processamento, largura de banda consumida ou número de usuários ativos podem ser registrados e analisados. Esse acompanhamento contínuo permite que o uso dos recursos seja monitorado, controlado e relatado, oferecendo transparência tanto para o provedor quanto para o cliente que utiliza o serviço.

Um aspecto importante desse modelo é que ele permite ao próprio usuário acompanhar e gerenciar o consumo de recursos computacionais. Isso proporciona maior controle sobre os custos e sobre a forma como a infraestrutura é utilizada. Diferentemente do que ocorre em ambientes tradicionais de TI, nos quais a capacidade costuma ser contratada de forma fixa e muitas vezes superior à demanda real, a computação em nuvem possibilita ajustar o uso de recursos praticamente em tempo real. Assim, processamento, armazenamento e diferentes serviços podem ser configurados ou modificados conforme as necessidades específicas do usuário ou da organização.

Esse nível de controle contribui para uma gestão mais eficiente dos recursos tecnológicos. Ao poder dimensionar e redimensionar os serviços conforme a demanda, o usuário reduz a possibilidade de manter recursos ociosos e evita gastos desnecessários. Provedores de nuvem normalmente disponibilizam ferramentas que permitem acompanhar métricas de consumo, visualizar relatórios detalhados de utilização e configurar alertas de custo. Esses mecanismos auxiliam na identificação de desperdícios e ajudam a encontrar oportunidades de otimização, como desligar instâncias que não estão sendo utilizadas, reduzir capacidades excessivas ou escolher serviços mais adequados às necessidades da aplicação.

Além dos benefícios financeiros, o modelo de pagamento baseado no consumo oferece maior flexibilidade e agilidade para usuários e organizações. A possibilidade de testar novas configurações, implantar aplicações temporárias ou ampliar recursos por um período limitado facilita o desenvolvimento de projetos e reduz riscos associados a investimentos elevados em infraestrutura. Dessa forma, a computação em nuvem permite que empresas experimentem novas soluções tecnológicas e expandam serviços conforme a evolução de suas demandas.

Portanto, o modelo de cobrança baseado no uso efetivo dos recursos representa um dos fatores que tornam a computação em nuvem atraente para organizações de diferentes portes. Ao alinhar os custos de TI ao nível real de utilização, essa característica contribui para uma gestão mais estratégica da infraestrutura, permitindo que os investimentos em TI acompanhem de forma mais precisa as necessidades e os objetivos do negócio.

1.4.4 Self service sob demanda

A característica de self-service sob demanda, também conhecida como autoatendimento sob demanda, refere-se à possibilidade de o próprio usuário provisionar, configurar e administrar recursos computacionais sempre que necessário, de forma autônoma e praticamente imediata, sem depender de intervenção direta do provedor do serviço. Em ambientes de computação em nuvem, essa funcionalidade normalmente é disponibilizada por meio de portais web, interfaces de gerenciamento ou APIs, que permitem solicitar recursos como VMs, serviços de armazenamento, redes ou aplicações de forma rápida e simplificada. Esse modelo representa uma mudança significativa em relação às infraestruturas tradicionais de TI, nas quais a disponibilização de novos recursos frequentemente dependia de processos internos demorados e da atuação direta de equipes técnicas.

Nesse contexto, diferentes usuários ou organizações podem acessar os serviços oferecidos pelo provedor de nuvem por meio da rede e solicitar os recursos de que necessitam de maneira direta. Cada usuário possui autonomia para escolher quais serviços utilizar como recursos de computação, armazenamento, plataformas de desenvolvimento ou sistemas de mensageria, e pode ativá-los ou configurá-los conforme suas demandas específicas. Todo esse processo ocorre de forma automatizada, permitindo que os recursos sejam disponibilizados em poucos minutos, sem a necessidade de contato manual com a equipe do provedor.

Outro aspecto importante é que esses serviços são disponibilizados a partir de uma infraestrutura compartilhada e gerenciada pelo provedor de nuvem. Embora múltiplos clientes utilizem os mesmos ambientes físicos de data center, cada usuário interage apenas com as camadas de serviço que lhe são disponibilizadas. Dessa forma, a complexidade associada à infraestrutura subjacente, como servidores físicos, redes, sistemas de virtualização e mecanismos de gerenciamento, permanece sob responsabilidade do provedor. Essa abstração permite que o usuário se concentre no uso dos serviços e no desenvolvimento de aplicações, sem precisar lidar diretamente com os detalhes técnicos da infraestrutura.

A característica de self-service também se relaciona com outras propriedades fundamentais da computação em nuvem, como elasticidade e serviços mensurados. Como o próprio usuário pode escolher quais recursos utilizar e em que quantidade, torna-se possível ajustar rapidamente o consumo de acordo com as necessidades de cada momento. Assim, recursos podem ser ampliados quando a demanda aumenta e reduzidos quando deixam de ser necessários. Esse comportamento está diretamente ligado ao modelo de pagamento baseado no consumo, no qual o cliente paga apenas pelos recursos efetivamente utilizados.

Além disso, o self-service sob demanda contribui significativamente para aumentar a agilidade e a eficiência dos processos de TI. A eliminação de etapas burocráticas, como solicitações formais, aprovações prolongadas e processos demorados de aquisição de infraestrutura, permite que equipes de desenvolvimento e operações respondam com maior rapidez às demandas do negócio. Esse aspecto é particularmente relevante em ambientes que exigem constante adaptação, como projetos de desenvolvimento de software, testes de novas soluções ou implantação de aplicações inovadoras.

Esse nível de autonomia também favorece a adoção de práticas modernas de desenvolvimento e operação de sistemas, como DevOps, CI e CD, nas quais a criação e a modificação de ambientes precisam ocorrer de maneira rápida e automatizada. Com o self-service, desenvolvedores e equipes técnicas podem criar ambientes de teste, ajustar configurações e implantar novas versões de aplicações sem depender de longos processos de provisionamento de infraestrutura.

Além da agilidade operacional, o autoatendimento sob demanda contribui para uma gestão mais eficiente dos recursos e dos custos. Como os usuários podem ativar ou desativar serviços conforme suas necessidades, torna-se possível alinhar o consumo de recursos às demandas reais das aplicações ou dos projetos em andamento. Isso reduz a ocorrência de recursos ociosos e permite um uso mais consciente da infraestrutura disponível.

Dessa forma, o self-service sob demanda representa um dos elementos que tornam a computação em nuvem mais flexível, acessível e eficiente. Ao permitir que os próprios usuários gerenciem o consumo de recursos de maneira direta e automatizada, essa característica simplifica o acesso à infraestrutura tecnológica e contribui para que organizações utilizem a TI de forma mais estratégica e alinhada às suas necessidades.

1.4.5 Pool de recursos

É uma das características fundamentais da computação em nuvem e está relacionado ao compartilhamento de recursos computacionais entre diferentes usuários ou aplicações. Nesse modelo, elementos como capacidade de processamento, memória, armazenamento e largura de banda são agrupados em uma infraestrutura comum e disponibilizados para múltiplos clientes de forma simultânea. Essa abordagem permite que os recursos sejam utilizados de maneira mais eficiente, pois são distribuídos conforme as necessidades de cada consumidor.

Os serviços de computação em nuvem baseiam-se justamente nesse princípio de compartilhamento de recursos de hardware, software e dados por meio da internet. Nesse contexto, empresas e indivíduos podem acessar um conjunto virtualizado de recursos computacionais mantidos por provedores de serviços especializados. Esses recursos, que incluem servidores, sistemas de armazenamento e componentes de rede, ficam localizados em data centers remotos e são administrados pelo provedor. O cliente, por sua vez, paga para utilizar esses recursos conforme sua demanda, sem a necessidade de adquirir ou manter infraestrutura própria.

Como esses recursos são gerenciados de forma centralizada, torna-se possível realizar uma alocação dinâmica e eficiente, distribuindo a capacidade disponível entre diferentes usuários de acordo com suas necessidades. Essa centralização permite que a infraestrutura seja utilizada de forma flexível, possibilitando aumentar ou reduzir recursos conforme a variação da demanda. Dessa maneira, organizações podem expandir suas operações com maior rapidez, sem precisar investir na construção ou manutenção de data centers próprios e sem lidar diretamente com a complexidade de gerenciar equipamentos físicos.

Ainda, o gerenciamento automatizado da infraestrutura contribui para garantir níveis adequados de segurança, monitoramento e desempenho. Provedores de nuvem utilizam ferramentas avançadas de gerenciamento para acompanhar o funcionamento dos recursos de forma contínua, a fim de identificar possíveis falhas e otimizar o uso da infraestrutura. Isso contribui para melhorar a eficiência operacional e aumentar a confiabilidade dos serviços oferecidos aos usuários.

De forma simplificada, a computação em nuvem utiliza redes de comunicação, na maioria das vezes a própria internet, para conectar usuários a uma plataforma que disponibiliza serviços computacionais sob demanda. Por meio dessa conexão, clientes podem solicitar e utilizar diferentes recursos hospedados em servidores remotos. Esses servidores atuam como intermediários no processamento das solicitações, facilitando a troca de dados entre dispositivos dos usuários e a infraestrutura de nuvem. Para garantir a proteção das informações, os ambientes de nuvem normalmente incorporam mecanismos de segurança e privacidade, como autenticação, criptografia e controle de acesso.

Outro aspecto importante é que a arquitetura de computação em nuvem não segue um único modelo rígido de implementação. Cada organização pode adotar soluções diferentes, dependendo de suas necessidades, do tipo de aplicação utilizada e dos requisitos de desempenho, segurança ou regulamentação. Essa flexibilidade é um dos fatores que tornam a computação em nuvem tão atraente, pois permite que empresas adaptem suas infraestruturas tecnológicas de acordo com as mudanças do mercado e com a evolução de suas atividades.

No modelo de pool de recursos, a infraestrutura do provedor é utilizada por múltiplos clientes ao mesmo tempo, em um ambiente conhecido como modelo multi-inquilino (multitenant). Nesse modelo, recursos físicos e virtuais são atribuídos e redistribuídos dinamicamente entre os usuários conforme suas demandas. Ao mesmo tempo, cada cliente mantém seu ambiente isolado dos demais, garantindo privacidade e segurança no uso dos serviços.

Outra característica associada ao pool de recursos é a independência de localização. Em geral, o usuário não possui controle direto nem conhecimento detalhado sobre a localização exata dos recursos utilizados, pois a infraestrutura pode estar distribuída em diferentes data centers. No entanto, em alguns casos, o cliente pode escolher a localização em um nível mais amplo, como país, região ou data center específico, especialmente quando existem requisitos relacionados a desempenho, regulamentação ou armazenamento de dados.

Entre os principais benefícios do pool de recursos está a redução de custos operacionais, já que as organizações deixam de investir na aquisição de equipamentos e na manutenção de uma infraestrutura própria. Além disso, a possibilidade de ajustar rapidamente a quantidade de recursos disponíveis promove maior agilidade para implantar novos serviços ou aplicações. A gestão centralizada também contribui para garantir alta disponibilidade, permitindo que os sistemas permaneçam acessíveis mesmo diante de picos de demanda ou de eventuais falhas técnicas.

Dessa forma, o pool de recursos representa um dos pilares da computação em nuvem, pois permite que a infraestrutura seja compartilhada de forma eficiente entre diferentes usuários. Essa abordagem

favorece uma utilização mais racional dos recursos computacionais, reduz desperdícios e contribui para a construção de ambientes tecnológicos mais econômicos, escaláveis e sustentáveis.



Lembrete

De forma resumida, as principais características da computação em nuvem são:

- **Acesso amplo via rede:** serviços acessados de qualquer lugar pela internet.
- **Elasticidade e escalabilidade:** permite aumentar ou reduzir a capacidade rapidamente.
- **Pagamento por uso:** o cliente paga apenas pelo que utilizar.
- **Acesso sob demanda:** recursos disponíveis quando necessário, sem intervenção humana do provedor.
- **Pool de recursos:** manutenção, segurança e atualizações ficam a cargo do provedor.

2 MODELOS DE COMPUTAÇÃO EM NUVEM

Assim como ocorre com os sistemas de informação e com as redes de computadores, não existe uma única abordagem capaz de atender igualmente a todas as empresas quando se trata de computação em nuvem. As organizações possuem diferentes objetivos, níveis de maturidade tecnológica, requisitos de segurança, restrições orçamentárias e demandas de desempenho, o que faz com que a escolha da solução de nuvem precise ser cuidadosamente analisada em cada contexto.

A computação em nuvem oferece diversas possibilidades de implementação e utilização, permitindo que empresas adotem estratégias alinhadas às suas necessidades específicas. Algumas organizações podem priorizar maior controle sobre a infraestrutura, enquanto outras buscam flexibilidade, escalabilidade ou redução de custos operacionais. Dessa forma, não existe uma "receita de bolo" única para a adoção da nuvem; a decisão envolve avaliar fatores técnicos, organizacionais e estratégicos.

Para atender a essa diversidade de necessidades, surgiram diferentes modelos de computação em nuvem, que definem formas distintas de disponibilização, gerenciamento e consumo dos recursos computacionais. Esses modelos possibilitam que as organizações escolham a alternativa mais adequada ao seu cenário, equilibrando aspectos como controle, segurança, escalabilidade e custo. Nos tópicos a seguir, serão apresentados os principais modelos de computação em nuvem e suas características.

2.1 Modelos de serviço

Os modelos de serviço definem o nível de controle que o usuário tem sobre a infraestrutura e a responsabilidade que ele compartilha com o provedor de nuvem. São divididos em três tipos, como listado e ilustrado a seguir: IaaS; PaaS; e SaaS.




Figura 11 – Modelos de serviço de computação em nuvem

Adaptada de: Mell e Grance (2011).

A IaaS oferece recursos computacionais básicos por meio da internet, como servidores virtuais, armazenamento e componentes de rede. Nesse modelo, as organizações utilizam esses recursos sob demanda, podendo ampliar ou reduzir a capacidade conforme a necessidade. Dessa forma, não é preciso investir diretamente em equipamentos físicos e na manutenção de infraestrutura própria.

A PaaS disponibiliza um ambiente completo para o desenvolvimento e execução de aplicações. Nesse modelo, os provedores de nuvem fornecem ferramentas, frameworks e serviços que auxiliam programadores a criar, testar, implantar e gerenciar softwares. Assim, os desenvolvedores podem concentrar seus esforços na lógica da aplicação, sem precisar administrar os detalhes da infraestrutura subjacente.

Já o SaaS corresponde à disponibilização de aplicações prontas para uso por meio da internet. Nesse caso, todos os aspectos de segurança, infraestrutura, manutenção do sistema e atualizações ficam sob responsabilidade do provedor de nuvem. Os usuários acessam o software remotamente, geralmente por meio de navegadores ou aplicativos, sem a necessidade de instalação local.

Para compreender adequadamente esses três modelos de serviço, é importante observar que eles apresentam uma estrutura hierárquica baseada em níveis de abstração e dependência, conforme ilustrado na figura a seguir.




Figura 12 – Hierarquia dos modelos de serviço de computação em nuvem

Adaptada de: Pinto (2025).

Na figura 12, vemos a IaaS na base da hierarquia dos modelos de serviço da computação em nuvem. Ou seja, a IaaS constitui a camada fundamental, responsável por fornecer os recursos computacionais essenciais, como VMs, armazenamento e redes. A partir dessa base, é construída a PaaS, que adiciona ferramentas e ambientes de desenvolvimento necessários para a criação e execução de aplicações. No nível mais alto encontra-se o SaaS, no qual as aplicações já estão prontas para utilização pelos usuários finais.

Assim, mesmo que o cliente não contrate diretamente todos os níveis de serviço, o uso de PaaS implica necessariamente a presença de uma infraestrutura subjacente baseada em IaaS. Da mesma forma, o SaaS depende tanto da plataforma quanto da infraestrutura que sustentam a aplicação, ou seja, dos serviços de PaaS e IaaS que já estão incorporados ao modelo. Essa organização em camadas demonstra que cada nível de serviço abstrai e gerencia os recursos do nível inferior, tornando o uso da nuvem progressivamente mais simples para o usuário à medida que se avança na pilha de serviços.

Nas próximas seções, aprofundamos nosso estudo em cada um dos modelos de serviço.

2.1.1 Infrastructure as a service (IaaS)

A IaaS representa um modelo de computação em nuvem bastante próximo da infraestrutura tradicional on-premises. Nesse modelo, os recursos de infraestrutura são disponibilizados por provedores de nuvem sob demanda e cobrados de acordo com o uso. Entre os principais recursos oferecidos estão serviços de armazenamento, processamento e virtualização, acessados pelos clientes por meio da internet ou de ambientes de nuvem.

Nesse tipo de serviço, a responsabilidade pela gestão dos diferentes componentes do sistema é compartilhada entre cliente e provedor. A organização que utiliza o IaaS permanece responsável pela administração do sistema operacional, pelos dados armazenados, pelas aplicações, pelos componentes de middleware e pelos ambientes de execução. Por outro lado, cabe ao provedor da nuvem gerenciar a infraestrutura física e fornecer acesso aos recursos essenciais, como rede, servidores, virtualização e sistemas de armazenamento necessários para o funcionamento do ambiente.



Observação

No modelo de serviço IaaS, o provedor de nuvem fornece os recursos de infraestrutura básicos, como servidores em VMs, armazenamento, redes e balanceamento de carga. Ao contratar o IaaS, é como se o cliente contratasse um data center virtual (Pinto, 2025).

No modelo de IaaS, o provedor disponibiliza ao cliente recursos computacionais essenciais, como processamento, armazenamento, redes e outros componentes fundamentais da infraestrutura de TI. Esses recursos permitem que o consumidor implante e execute diferentes tipos de softwares, incluindo sistemas operacionais e aplicações. Embora o usuário não tenha controle direto sobre a infraestrutura física da nuvem, ele pode administrar os sistemas operacionais, o armazenamento e as aplicações instaladas, além de possuir controle limitado sobre alguns elementos de rede, como regras de firewall.

Nesse contexto, é desnecessário que a organização mantenha ou atualize um data center próprio. Toda a gestão da infraestrutura física é realizada pelo provedor de nuvem. O acesso e a administração dos recursos contratados são realizados por meio de painéis de controle disponibilizados pelo provedor ou através de interfaces de programação de aplicações, conhecidas como APIs.

Outra característica importante desse modelo é a possibilidade de ajustar os recursos conforme a demanda. As empresas podem contratar apenas os componentes necessários para suas operações e ampliar ou reduzir essa capacidade sempre que necessário. Essa flexibilidade reduz custos operacionais e elimina a necessidade de investimentos constantes em manutenção de infraestrutura, tornando o modelo economicamente atrativo.

Além disso, o IaaS é particularmente adequado para a criação de ambientes de desenvolvimento e teste. As organizações podem provisionar rapidamente a infraestrutura necessária para essas atividades, utilizar os recursos durante o período desejado e, posteriormente, desativá-los quando não forem mais necessários. Assim, o pagamento ocorre apenas pelo tempo e pelos recursos efetivamente utilizados.

As características principais do modelo IaaS são:

- **Responsabilidade compartilhada:** o provedor gerencia a infraestrutura física (servidores e energia), enquanto o cliente gerencia o sistema operacional, aplicações e segurança lógica.
- **Flexibilidade e controle:** permite migrar aplicações existentes e ter controle total sobre o ambiente.
- **Custo otimizado:** geralmente pago por uso (pay as you go).

Entre as principais vantagens desse modelo destaca-se o elevado nível de flexibilidade. O provedor de nuvem oferece os componentes básicos da infraestrutura, como VMs, armazenamento e redes, enquanto o cliente utiliza esses recursos alugados para configurar o ambiente conforme suas necessidades, mantendo controle sobre o sistema operacional, as aplicações e os dados.

Por outro lado, algumas limitações podem estar associadas ao uso de soluções de IaaS. Questões relacionadas à segurança do provedor, ao compartilhamento de recursos em ambientes de multilocalização e à confiabilidade do serviço podem representar desafios. Entretanto, esses riscos podem ser minimizados por meio da escolha de provedores consolidados no mercado, com boa reputação e histórico consistente de confiabilidade.

Entre os principais provedores de nuvem pública que oferecem serviços baseados em IaaS destacam-se o AWS, Microsoft Azure e GCP. Exemplos de serviços desse tipo incluem, respectivamente, o Amazon EC2, o Azure Virtual Machines e o Google Compute Engine (GCE) no GCP.

2.1.2 Platform as a service (PaaS)

O modelo de PaaS representa um nível adicional de abstração em relação à infraestrutura tradicional on-premises, posicionando-se acima do modelo de IaaS na hierarquia dos serviços de computação em nuvem.

Nesse modelo, o provedor de nuvem é responsável por hospedar e gerenciar os componentes de hardware e software necessários para o funcionamento da plataforma. Assim, os usuários têm acesso a um ambiente completo que pode ser utilizado como uma solução integrada, um conjunto de ferramentas e serviços (stack) ou ainda como uma plataforma conectada à internet para o desenvolvimento e execução de aplicações.

O PaaS é especialmente vantajoso para desenvolvedores e equipes de programação, pois oferece os recursos necessários para criar, testar, implantar e gerenciar aplicações sem que seja necessário lidar diretamente com a configuração e manutenção da infraestrutura ou da plataforma que normalmente suportaria essas atividades. Dessa forma, os profissionais podem concentrar seus esforços no desenvolvimento das funcionalidades das aplicações.



Observação

No modelo de serviço PaaS, o provedor oferece uma plataforma completa para desenvolvimento, execução e gerenciamento de aplicações. O cliente não se preocupa com o sistema operacional, patches ou infraestrutura subjacente; apenas com a sua aplicação e os dados. Para o cliente, é como ter um ambiente de desenvolvimento pronto para uso, com todos os recursos necessários para construir e executar os aplicativos (Pinto, 2025).

No PaaS, o desenvolvedor continua responsável pela criação do código, pela compilação e pelo gerenciamento das aplicações. Entretanto, todas essas atividades são realizadas sem a necessidade de lidar com tarefas relacionadas à manutenção de hardware ou à atualização de softwares da infraestrutura. O ambiente necessário para o desenvolvimento, execução e implantação das aplicações é disponibilizado diretamente pelo provedor de nuvem.

Outra vantagem desse modelo é que ele permite aos desenvolvedores utilizar frameworks e ferramentas que facilitam a criação e personalização de aplicações, especialmente de aplicações web. A plataforma disponibiliza diversos componentes de software prontos para uso, o que possibilita acelerar o processo de desenvolvimento e reduzir a quantidade de código que precisa ser escrito manualmente.

Nesse contexto, a capacidade oferecida ao consumidor consiste na possibilidade de implantar, na infraestrutura de nuvem, aplicações desenvolvidas ou adquiridas pela própria organização, utilizando linguagens de programação, bibliotecas, serviços e ferramentas que são suportados pelo provedor da plataforma. Embora o usuário não tenha controle direto sobre a infraestrutura subjacente como redes, servidores, sistemas operacionais ou armazenamento, ele mantém controle sobre as aplicações implantadas e, em alguns casos, sobre determinadas configurações do ambiente em que essas aplicações são executadas.

As características principais do modelo PaaS são:

- **Foco no desenvolvimento:** ideal para desenvolvedores que querem agilidade.
- **Menos controle, mais simplicidade:** o cliente perde controle sobre o sistema operacional, mas ganha em produtividade, já que o provedor cuida da manutenção.
- **Escalabilidade automática:** a plataforma geralmente escala a aplicação automaticamente conforme a demanda.

Entre os principais benefícios do modelo PaaS destaca-se a simplificação do processo de desenvolvimento, testes e implantação de aplicações, pois grande parte da complexidade da infraestrutura é abstraída pela plataforma. Assim, as equipes de desenvolvimento podem concentrar seus esforços na criação da lógica de negócio e na inovação das aplicações. Além disso, o modelo contribui para aumentar a produtividade dos desenvolvedores, reduzir o tempo de disponibilização de novas soluções no mercado (time to market) e otimizar custos operacionais, já que a cobrança geralmente ocorre de acordo com o consumo efetivo de recursos.

Por outro lado, a utilização de plataformas PaaS também apresenta algumas limitações. Uma delas é a possibilidade de dependência significativa do provedor de nuvem, fenômeno conhecido como vendor lock-in, que pode dificultar a migração de aplicações para outras plataformas. Além disso, o usuário possui menor controle sobre o ambiente subjacente, o que pode restringir determinadas personalizações ou configurações mais específicas da infraestrutura. Aspectos relacionados à segurança, conformidade regulatória e localização dos dados também podem se tornar mais complexos, especialmente em setores que possuem exigências legais rigorosas. Outro ponto a considerar é que algumas plataformas podem impor restrições tecnológicas, como o suporte apenas a determinadas linguagens de programação, frameworks ou versões específicas de ferramentas.

Entre os exemplos mais conhecidos de plataformas PaaS destacam-se serviços como AWS Elastic Beanstalk, Azure App Service, Google App Engine, Heroku e Red Hat OpenShift. Esses serviços fornecem ambientes completos que auxiliam no desenvolvimento, na implantação e também no gerenciamento de aplicações em nuvem.

2.1.3 Software as a service (SaaS)

O SaaS, também chamado de serviço de aplicações em nuvem, representa o nível mais completo dentro dos modelos de computação em nuvem. Nesse modelo, uma aplicação inteira é disponibilizada ao usuário final por meio da internet, sendo totalmente administrada pelo provedor de nuvem e normalmente acessada através de um navegador web.

Nesse tipo de serviço, atividades como atualizações do sistema, correções de falhas e outras tarefas relacionadas à manutenção do software ficam sob responsabilidade do provedor. Ao usuário cabe apenas acessar a aplicação por meio de um painel de controle ou, em alguns casos, por meio de uma API.

Dessa forma, não há necessidade de instalar programas em computadores individuais, o que simplifica o processo de utilização e facilita o acesso compartilhado por diferentes usuários de maneira mais prática e confiável.



Observação

No modelo de serviço SaaS, o provedor fornece aplicativos completos, acessíveis via internet. O cliente não precisa se preocupar com a infraestrutura, o sistema operacional ou a manutenção do software. Basta acessar o aplicativo através de um navegador ou aplicativo móvel. Nesse modelo, o cliente está essencialmente "alugando" um software (Pinto, 2025).

Grande parte das pessoas já utilizou algum tipo de SaaS no cotidiano, muitas vezes sem perceber. Um exemplo comum é o uso de serviços de e-mail baseados na web, como Gmail ou Outlook, nos quais basta realizar o login para acessar mensagens e arquivos a partir de qualquer dispositivo conectado à internet.

Para empresas de pequeno porte, o SaaS pode ser uma alternativa bastante vantajosa, especialmente quando não há equipes de TI especializadas ou infraestrutura de rede suficiente para instalar, manter e atualizar softwares localmente. Esse modelo também é adequado para aplicações que exigem pouca personalização ou que são utilizadas de forma esporádica.

Entretanto, a praticidade proporcionada pelo SaaS pode implicar algumas limitações. Embora esse modelo reduza significativamente o esforço relacionado à manutenção e à administração do sistema, ele pode resultar em menor controle sobre aspectos como desempenho, segurança e personalização. Por esse motivo, é fundamental selecionar provedores confiáveis e com boa reputação no mercado.

No modelo SaaS, o consumidor tem acesso às aplicações executadas diretamente na infraestrutura de nuvem do provedor. Essas aplicações podem ser utilizadas a partir de diferentes dispositivos, geralmente por meio de interfaces leves, como navegadores web, caso típico de serviços de e-mail, ou também por meio de interfaces de programação. Nesse cenário, o usuário não possui controle ou gerenciamento sobre a infraestrutura de nuvem subjacente, incluindo elementos como redes, servidores, sistemas operacionais e armazenamento, podendo apenas ajustar algumas configurações específicas relacionadas ao uso da aplicação.

Dessa forma, o provedor disponibiliza o software completo e pronto para utilização por meio da internet. O acesso ocorre normalmente por um navegador ou por aplicativos específicos, eliminando a necessidade de instalação ou manutenção local do programa.

As características principais do modelo SaaS são:

- **Pronto para usar:** a solução está totalmente pronta, e o usuário não precisa se preocupar com o desenvolvimento, infraestrutura ou manutenção.

- **Menor responsabilidade:** o provedor é totalmente responsável pela aplicação, infraestrutura e segurança.
- **Fácil acesso:** acesso de qualquer lugar, a qualquer momento, via internet.
- **Baixo custo de manutenção:** geralmente baseado em modelo de assinatura, no qual os custos de infraestrutura, atualização e suporte são responsabilidade do provedor.

A adoção do SaaS pode gerar ganhos expressivos de produtividade e competitividade, principalmente porque as aplicações ficam centralizadas na nuvem e podem ser acessadas remotamente por diferentes usuários. Isso favorece o trabalho colaborativo em tempo real, mesmo entre equipes distribuídas geograficamente. Além disso, como o provedor assume a responsabilidade pela manutenção técnica, monitoramento e atualizações do sistema, a complexidade operacional para a organização é significativamente reduzida. Outro benefício importante está relacionado à escalabilidade e flexibilidade, já que novos usuários, módulos e funcionalidades podem ser adicionados rapidamente conforme a demanda do negócio. A integração com outros sistemas por meio de APIs também contribui para a troca eficiente de dados entre diferentes plataformas. Somado a isso, muitos provedores oferecem níveis elevados de segurança e aderência a normas e legislações, como a LGPD, sem que a empresa precise investir significativamente em infraestrutura própria.

Apesar dessas vantagens, o modelo SaaS também apresenta algumas limitações. O menor controle sobre a aplicação e sobre a infraestrutura que a suporta pode restringir customizações mais avançadas. Além disso, a dependência do provedor e da conexão com a internet pode afetar a disponibilidade do serviço em situações de falha ou instabilidade, além de aumentar o risco de vendor lock-in. Questões relacionadas à segurança e à privacidade dos dados também podem gerar preocupações, principalmente em organizações que operam em setores com regulamentações mais rigorosas. Outro aspecto a considerar é que os custos recorrentes de assinatura podem crescer ao longo do tempo, especialmente quando há aumento no número de usuários ou na quantidade de funcionalidades contratadas.

Entre os exemplos mais conhecidos de soluções SaaS estão plataformas como Google Workspace (Gmail, Docs e Drive), Microsoft 365, Salesforce, Dropbox e Red Hat Insights.

2.1.4 Comparação dos modelos de serviço de computação em nuvem

A definição do modelo de serviço mais adequado depende diretamente das necessidades de cada organização. Empresas que necessitam de maior controle sobre a infraestrutura tendem a optar pelo IaaS. Já aquelas que desejam concentrar seus esforços no desenvolvimento de aplicações podem se beneficiar mais do PaaS. Por outro lado, quando a prioridade é utilizar um software pronto, com mínima preocupação com infraestrutura ou manutenção, o SaaS torna-se a alternativa mais simples.

De modo geral, os modelos de serviço em computação em nuvem determinam o nível de controle exercido pelo usuário sobre a infraestrutura e estabelecem como as responsabilidades são divididas entre o cliente e o provedor de nuvem.

O quadro comparativo apresentado a seguir ilustra essa divisão de responsabilidades entre a organização, representada pela equipe de TI interna e o provedor de nuvem em cada modelo de serviço.

Quadro 1 – Comparativo dos modelos de serviço de computação em nuvem

	On-Premises	IaaS	PaaS	SaaS
Aplicações	TI interna	TI interna	TI interna	Provedor de nuvem
Dados	TI interna	TI interna	TI interna	Provedor de nuvem
Runtime	TI interna	TI interna	Provedor de nuvem	Provedor de nuvem
Middelware	TI interna	TI interna	Provedor de nuvem	Provedor de nuvem
O/S	TI interna	TI interna	Provedor de nuvem	Provedor de nuvem
Virtualização	TI interna	Provedor de nuvem	Provedor de nuvem	Provedor de nuvem
Servidores	TI interna	Provedor de nuvem	Provedor de nuvem	Provedor de nuvem
Storage	TI interna	Provedor de nuvem	Provedor de nuvem	Provedor de nuvem
Rede	TI interna	Provedor de nuvem	Provedor de nuvem	Provedor de nuvem

Adaptado de: Pinto (2025).

O quadro demonstra que, à medida que se evolui de um ambiente tradicional para soluções em nuvem, ocorre uma transferência gradual das tarefas de gerenciamento da infraestrutura e da plataforma para o provedor, permitindo que o cliente concentre seus esforços principalmente no uso das aplicações e no desenvolvimento de soluções para o negócio.

No modelo tradicional on-premises, toda a gestão da infraestrutura e dos sistemas é responsabilidade da equipe interna de TI da organização. Isso inclui desde a administração da rede, armazenamento e servidores, até camadas como virtualização, sistema operacional, middleware e ambientes de execução, além do gerenciamento dos dados e das aplicações. Embora esse modelo ofereça elevado nível de controle sobre todos os componentes do ambiente tecnológico, ele também exige investimentos significativos em infraestrutura, maior complexidade na operação e equipes qualificadas para manter o funcionamento adequado de todo o sistema.

No modelo IaaS, parte dessas responsabilidades passa a ser assumida pelo provedor de nuvem, que fica encarregado da gestão da infraestrutura física e dos recursos de virtualização, incluindo rede, armazenamento e servidores. Nesse caso, a equipe de TI da organização continua responsável pela administração do sistema operacional, middleware, ambientes de execução, aplicações e dados. Esse modelo contribui para a redução de custos relacionados à aquisição e manutenção de hardware, ao mesmo tempo que mantém um nível considerável de controle por parte da empresa.

As vantagens do IaaS são (The cloud..., 2022): provisionamento acelerado de recursos de computação e armazenamento; amplo ecossistema de parceiros tecnológicos e operadores de telecomunicações; infraestrutura escalável para suportar capacidades avançadas, como IA e análise de dados; e acesso a recursos especializados em cibersegurança.

No caso do PaaS, o provedor de nuvem amplia ainda mais seu papel, assumindo também a administração do sistema operacional, do middleware e do ambiente de execução, além da infraestrutura. Com isso, a equipe de TI da organização passa a concentrar seus esforços principalmente no desenvolvimento e gerenciamento das aplicações e no tratamento dos dados. Esse modelo facilita o processo de desenvolvimento de software, reduz a complexidade da infraestrutura e permite acelerar a disponibilização de aplicações no mercado.

As vantagens do PaaS são (The cloud..., 2022): maior rapidez na aquisição e disponibilização de software e hardware necessários para que desenvolvedores criem aplicações; desenvolvimento de aplicações mais rápido e flexível, reduzindo o tempo necessário para a digitalização de processos; participação de novos perfis no ecossistema DevOps, contribuindo para a evolução de processos e para a automação de fluxos de trabalho; e aceleração da modernização de aplicações, impulsionada por contextos recentes, como a pandemia e os períodos de instabilidade econômica.

O modelo SaaS, por sua vez, possibilita que praticamente toda a estrutura tecnológica seja gerenciada pelo provedor de nuvem. Isso inclui não apenas a infraestrutura e a plataforma, mas também as próprias aplicações. Nesse cenário, a organização utiliza o software disponibilizado e se responsabiliza basicamente pela gestão das informações inseridas no sistema. Esse modelo oferece grande simplicidade de uso, rápida implementação e menor necessidade de administração técnica, sendo amplamente utilizado em aplicações padronizadas, como serviços de e-mail, ferramentas de colaboração e sistemas de gestão de relacionamento com clientes (CRM).

As vantagens do SaaS são (The cloud..., 2022): aplicações centralizadas na nuvem, que suporta diversos casos de uso; acesso mais rápido a novas versões de aplicações e tecnologias; ecossistemas amplos de parceiros, incluindo telcos, provedores de CDN, integradores e fornecedores de hardware e software; e extensão de serviços existentes para apoiar iniciativas de transformação digital.

Dessa forma, observa-se que, à medida que se evolui do modelo on-premises para soluções baseadas em SaaS, ocorre uma redução gradual das responsabilidades operacionais da equipe interna de TI, ao mesmo tempo que aumenta a dependência em relação ao provedor de nuvem. Em contrapartida, essa mudança proporciona maior simplicidade de gestão, maior capacidade de escalabilidade e redução dos custos operacionais relacionados à infraestrutura tecnológica.

2.2 Modelos de implantação

São quatro os modelos de implantação de arquitetura em nuvem (Mell; Grance, 2011): nuvem pública; nuvem privada; nuvem comunitária; e nuvem híbrida.




Figura 13 – Modelos de implantação de computação em nuvem

Adaptada de: Mell e Grance (2011).

Com a evolução da computação em nuvem, a forma como as organizações utilizam e combinam os diferentes modelos também passou por transformações. Atualmente, tornou-se comum a adoção de estratégias híbridas e multicloud, que permitem integrar diferentes ambientes de nuvem de acordo com as necessidades da empresa. No entanto, essas abordagens não substituem os modelos clássicos de implantação, mas funcionam como uma forma de ampliá-los e torná-los mais flexíveis.

Nesse contexto, é importante destacar que multicloud não é considerado um modelo de implantação, segundo o NIST (Mell; Grance, 2011). Trata-se, na verdade, de uma estratégia que envolve a utilização simultânea de múltiplas nuvens públicas e/ou privadas, geralmente de diferentes provedores. Essa abordagem permite que as organizações distribuam cargas de trabalho, aumentem a redundância e evitem dependência de um único fornecedor.

Dessa forma, a decisão sobre qual modelo de implantação adotar depende de diversos fatores, como requisitos de segurança, necessidade de flexibilidade e características do modelo de negócio da organização. Cada alternativa apresenta benefícios e limitações específicos, que precisam ser analisados de acordo com o contexto de uso. Esses aspectos serão discutidos com mais detalhes nas próximas seções.

2.2.1 Nuvem pública

No modelo de nuvem pública, os serviços de computação são disponibilizados por um provedor externo e compartilhados entre diversos clientes. Nesse cenário, os recursos de infraestrutura e as aplicações são acessados pela internet e cobrados conforme o consumo, o que proporciona grande escalabilidade, flexibilidade e reduz a necessidade de investimentos iniciais em equipamentos.

Nesse tipo de implantação, a infraestrutura é destinada ao uso amplo por diferentes usuários ou organizações. Ela pode ser de propriedade, gerenciada e operada por empresas privadas, instituições acadêmicas, organizações governamentais ou até mesmo por uma combinação dessas entidades. Normalmente, toda a estrutura física está localizada nas instalações do próprio provedor de serviços em nuvem.

Entre os modelos de implantação existentes, a nuvem pública é atualmente o mais difundido. Nesse formato, os recursos computacionais são fornecidos por empresas especializadas, como a Amazon, com o AWS, a Microsoft, com o Azure, e a Google, com o Google Cloud, sendo disponibilizados aos usuários por meio da internet.

Entre os principais benefícios desse modelo estão a elevada capacidade de escalabilidade, o baixo custo inicial, já que o pagamento ocorre apenas pelos recursos utilizados, e a eliminação da necessidade de gerenciar diretamente o hardware físico e a infraestrutura de data centers.

Por outro lado, a nuvem pública também apresenta algumas limitações. Como a infraestrutura pertence ao provedor, o nível de controle direto por parte da organização usuária é menor. Além disso, podem surgir preocupações relacionadas à conformidade regulatória e à segurança dos dados, embora os grandes provedores normalmente ofereçam mecanismos avançados de proteção e acordos contratuais que garantem altos padrões de segurança.

Outra estratégia frequentemente associada à nuvem pública é o multicloud, que consiste na utilização simultânea de serviços oferecidos por dois ou mais provedores de nuvem pública. Essa abordagem permite reduzir a dependência de um único fornecedor (conhecida como vendor lock-in), aproveitar recursos específicos de diferentes plataformas e aumentar a resiliência das aplicações. Entretanto, o uso de múltiplos provedores também pode tornar o gerenciamento mais complexo, elevar os custos operacionais e exigir equipes com conhecimento técnico em diversas tecnologias e ambientes de nuvem.

2.2.2 Nuvem privada

No modelo de nuvem privada, a infraestrutura de computação é dedicada exclusivamente a uma única organização. Esse tipo de ambiente pode ser administrado internamente pela própria empresa ou operado por um provedor terceirizado. Por oferecer maior nível de controle, possibilidade de personalização e maior proteção dos dados, costuma ser adotado por organizações que possuem exigências rigorosas relacionadas ao desempenho, à conformidade regulatória ou à confidencialidade das informações.

Nesse formato, a infraestrutura de nuvem é projetada para atender apenas uma organização e seus diferentes usuários internos, como departamentos ou unidades de negócio. A gestão desse ambiente pode ser realizada pela própria empresa, por um terceiro especializado ou por uma combinação dessas duas abordagens. Além disso, a infraestrutura pode estar localizada tanto nas instalações da organização quanto em ambientes externos. De acordo com Rocha (2020), o número de usuários que acessam esse tipo de nuvem é restrito, geralmente limitado aos membros da própria organização ou a um grupo específico de usuários autorizados. Por se tratar de uma infraestrutura de uso exclusivo, o proprietário possui maior autonomia para definir políticas de gerenciamento e estabelecer níveis mais elevados de confidencialidade no armazenamento e no tratamento das informações.

Em outras palavras, na nuvem privada os recursos computacionais são utilizados exclusivamente por uma única organização. Esses recursos podem ser hospedados internamente, no próprio data center da empresa, ou disponibilizados externamente por um provedor especializado, mantendo-se ainda assim o uso dedicado à organização.

Entre as principais vantagens desse modelo estão o alto grau de controle sobre a infraestrutura, a possibilidade de adaptar a arquitetura tecnológica às necessidades específicas da empresa e a maior facilidade para atender requisitos de segurança e conformidade.

Por outro lado, a nuvem privada também apresenta algumas limitações. Normalmente, exige investimentos iniciais mais elevados, além de demandar que a própria organização seja responsável pela administração, manutenção e atualização da infraestrutura. Outro fator a considerar é que a escalabilidade pode ser limitada pela capacidade de hardware disponível.

2.2.3 Nuvem híbrida

O modelo de nuvem híbrida surge da integração de diferentes ambientes de nuvem, normalmente combinando nuvem pública e nuvem privada. Essa abordagem permite que dados e aplicações sejam transferidos entre os ambientes, oferecendo maior flexibilidade para que as organizações utilizem cada

infraestrutura de acordo com suas necessidades específicas. Dessa forma, informações sensíveis podem permanecer em ambientes privados, enquanto a nuvem pública é utilizada para ampliar a capacidade computacional ou reduzir custos operacionais.

De forma mais técnica, a nuvem híbrida corresponde à composição de duas ou mais infraestruturas de nuvem distintas, como privada, pública ou comunitária, que continuam operando como ambientes independentes, mas são conectadas por tecnologias que possibilitam a portabilidade de dados e aplicações entre elas. Esse tipo de integração pode ser realizado por meio de soluções padronizadas ou proprietárias, permitindo, por exemplo, o uso de técnicas como cloud bursting, nas quais cargas de trabalho são direcionadas para a nuvem pública quando há aumento na demanda por recursos.

Na prática, esse modelo permite que as organizações utilizem a nuvem privada para hospedar aplicações críticas ou dados sensíveis, enquanto a nuvem pública é empregada para atender demandas variáveis, picos de processamento ou aplicações menos críticas. Essa combinação permite aproveitar os benefícios de ambos os ambientes.

Entre as principais vantagens da nuvem híbrida estão a flexibilidade para movimentar cargas de trabalho entre diferentes ambientes, maior controle sobre a segurança de informações sensíveis e a possibilidade de aproveitar a escalabilidade praticamente ilimitada da nuvem pública.

Em contrapartida, a adoção desse modelo apresenta alguns desafios. A integração entre ambientes distintos pode tornar a gestão da infraestrutura mais complexa, além de exigir ferramentas e estratégias adequadas para garantir a comunicação e a interoperabilidade entre as diferentes nuvens.

Além disso, em alguns cenários a estratégia híbrida pode ser combinada com abordagens de multicloud, nas quais a organização utiliza serviços de diferentes provedores de nuvem pública. Essa prática ajuda a reduzir a dependência de um único fornecedor e permite explorar os recursos específicos de cada plataforma, embora também aumente a complexidade de administração dos ambientes.

2.2.4 Nuvem comunitária

A nuvem comunitária é um modelo de implantação em que a infraestrutura é compartilhada por diversas organizações que possuem objetivos, requisitos ou regulamentações semelhantes. Esse tipo de ambiente é comum em setores como governo, saúde ou educação, nos quais diferentes instituições precisam seguir padrões específicos de segurança, privacidade e conformidade. Nesse modelo, os recursos e os custos da infraestrutura são divididos entre os participantes, ao mesmo tempo que são mantidos níveis adequados de governança e proteção da informação.

Nesse modelo, a infraestrutura de nuvem é projetada para atender exclusivamente uma comunidade formada por organizações que compartilham interesses comuns, como missão institucional, políticas de operação ou exigências regulatórias. A gestão desse ambiente pode ser realizada por uma ou mais organizações pertencentes à própria comunidade, por um provedor terceirizado ou por uma combinação dessas alternativas. Além disso, a infraestrutura pode estar localizada tanto nas instalações de uma das organizações participantes quanto em ambientes externos.

Em termos de características, a nuvem comunitária apresenta um modelo intermediário entre a nuvem privada e a nuvem pública. Ela permite o compartilhamento de recursos entre as instituições participantes, ao mesmo tempo que preserva um nível significativo de controle sobre políticas de segurança e governança. Esse modelo também estimula a colaboração entre organizações com interesses semelhantes, facilitando o compartilhamento seguro de dados, aplicações e boas práticas, além de permitir a padronização de requisitos de conformidade e proteção da informação.

Entre os benefícios desse tipo de implantação está a possibilidade de reduzir custos quando comparada a uma nuvem privada dedicada, já que a infraestrutura é utilizada coletivamente pelas organizações da comunidade. Outro ponto positivo é a maior facilidade em atender regulamentações específicas de determinados setores, uma vez que o ambiente pode ser projetado considerando essas exigências desde o início.

Por outro lado, a nuvem comunitária pode apresentar alguns obstáculos. A administração compartilhada acaba tornando os processos de governança mais complexos, pois envolve a coordenação entre várias organizações com diferentes necessidades e prioridades. Por esse motivo, é fundamental estabelecer acordos claros sobre responsabilidades, divisão de custos, políticas de uso e níveis de serviço para garantir o funcionamento adequado do ambiente.

2.3 Principais provedores e serviços em nuvem do mercado

Antes de apresentar os principais provedores de serviços em computação em nuvem, é importante compreender que a relação entre quem consome soluções na nuvem e quem as provê está fundamentada em um contexto essencialmente comercial. Uma organização oferece serviços tecnológicos a outra com a finalidade de apoiar, otimizar ou até mesmo viabilizar suas atividades operacionais e estratégicas. Assim, quando uma empresa terceiriza recursos ou soluções de tecnologia que passam a sustentar ou automatizar processos de negócio, a organização contratada assume o papel de provedora de serviços, contribuindo diretamente para a geração de valor para o cliente.



Observação

Um serviço pode ser entendido como um benefício fornecido por uma organização a outra, com o objetivo de atender a determinadas necessidades e gerar valor para quem o utiliza. No contexto da computação em nuvem, ao apoiar ou viabilizar processos de negócio, o fornecedor de serviços de cloud assume o papel de provedor de serviços organizacionais, contribuindo para a melhoria da eficiência operacional, para a continuidade das operações e para o cumprimento dos objetivos estratégicos da organização (Veras, 2015).

De modo geral, os serviços apresentam algumas características fundamentais. Uma delas é a geração de valor, que pode ser gerenciado e, em alguns casos, mensurado pela organização que os utiliza. Outra característica importante é a intangibilidade: embora os efeitos do serviço possam ser percebidos pelos

usuários, o serviço em si não possui forma física. Por esse motivo, nem sempre é possível medir com precisão o serviço prestado, seus resultados ou os benefícios efetivamente obtidos.

Além disso, os serviços são normalmente produzidos e consumidos ao mesmo tempo, o que significa que não podem ser estocados ou avaliados previamente. Também se destacam por depender da integração de diferentes elementos, como processos organizacionais, pessoas, conhecimento, experiências e recursos tecnológicos de infraestrutura, que atuam de forma coordenada para atender a uma necessidade específica.

Em um ambiente de computação tradicional, as principais partes interessadas são os provedores e os consumidores: os consumidores utilizam, possuem, mantêm e atualizam os sistemas, enquanto os provedores lidam com a venda, instalação, licenciamento, consultoria e manutenção da tecnologia envolvida. Já em um ambiente de computação em nuvem, existem outros atores e a organização se torna um pouco mais complexa.

A figura a seguir apresenta uma visão geral dos principais atores envolvidos no ecossistema de computação em nuvem e de suas respectivas responsabilidades. Essa estrutura evidencia como diferentes funções se articulam para viabilizar a oferta, o controle e o consumo de serviços em nuvem.




Figura 14 – Principais atores em serviços de computação em nuvem

Fonte: Veras (2015, p. 51).

Segundo Lopes e Souza Neto (2015), os principais atores em um serviço de computação em nuvem são:

- **Consumidor:** indivíduo ou organização que contrata e utiliza produtos e serviços oferecidos na nuvem.
- **Provedor:** indivíduo, organização ou entidade responsável por disponibilizar e manter os serviços de computação em nuvem para os usuários ou partes interessadas.
- **Intermediário:** entidade que administra o uso, o desempenho e a entrega dos serviços de nuvem, além de intermediar e gerenciar o relacionamento entre o provedor e o consumidor.

- **Auditor:** parte responsável por realizar avaliações independentes dos serviços de nuvem, analisando aspectos como operações do sistema de informação, implementação, desempenho e segurança.
- **Operador:** encarregado de fornecer a conectividade e o transporte necessários para que os serviços de nuvem sejam acessados pelos consumidores a partir dos provedores.

Existe ainda uma diferenciação dentro do consumidor de nuvem, que separa o cliente do usuário. O cliente corresponde à organização ou pessoa que adquire o serviço junto a um fornecedor, estabelecendo uma relação comercial e de confiança com o provedor. Já o usuário é quem efetivamente utiliza o serviço para realizar determinadas atividades, podendo ou não ser a mesma pessoa ou organização responsável pela contratação e pagamento do serviço.

De acordo com Veras (2015), os papéis de usuário e cliente podem ser explicados da seguinte forma:

- **Usuário:** indivíduo ou grupo que utiliza o serviço diretamente em suas atividades cotidianas, sendo o principal beneficiário de sua utilização.
- **Cliente:** entidade responsável por contratar o serviço, definir os requisitos funcionais, estabelecer os níveis de qualidade esperados e assumir os investimentos relacionados. O cliente tende a avaliar o serviço sob uma perspectiva mais estratégica, diferente da visão do usuário final.

Vimos que o provedor é a organização responsável por desenvolver, disponibilizar e operar o serviço, geralmente seguindo suas próprias políticas e atuando em um ambiente diferente daquele do cliente.

São diversos os provedores de serviços em nuvem que atuam no mercado, porém, historicamente, três são pioneiros e se tornaram referência (Pinto, 2025). Esses três provedores principais são os que aparecem na lista e na figura a seguir, com seus respectivos logos.

- AWS.
- Microsoft Azure.
- Google Cloud Platform (GCP).



Figura 15 – Principais provedores de computação em nuvem

Adaptada de: Pinto (2025).

Os principais provedores de computação em nuvem do mercado disponibilizam um portfólio abrangente de soluções, contemplando os diferentes modelos de serviço apresentados anteriormente neste tópico, como IaaS, PaaS e SaaS. Apesar de todos oferecerem serviços nessas categorias, cada provedor adota estratégias, arquiteturas e áreas de especialização próprias, o que resulta em diferenças na forma como os recursos são disponibilizados e gerenciados.

Ou seja, embora os principais provedores de computação em nuvem atuem nos três modelos de serviço (infraestrutura, plataforma e software), cada um apresenta áreas de maior destaque em função de sua trajetória e estratégia de mercado. A Amazon, através da sua subsidiária AWS, mantém forte liderança em IaaS, sendo reconhecida pela robustez e variedade de recursos nesse segmento, ainda que também ofereça soluções mais abrangentes. Já o Google e seu conjunto de serviços de computação em nuvem, denominado GCP, tem tradição principalmente em SaaS, sendo o Google Workspace seu principal produto, apesar de atuar fortemente também em PaaS, análise de dados e IA. Por sua vez, a Microsoft apresenta o Microsoft Cloud, um ecossistema bastante completo e integrado, com forte presença nos três modelos (IaaS, PaaS e SaaS), especialmente voltado ao ambiente corporativo e à integração com soluções já amplamente utilizadas pelas organizações. Duas das soluções mais tradicionais do Microsoft Cloud são Microsoft Azure (IaaS/PaaS) e Microsoft 365/Dynamics 365 (SaaS). A figura a seguir ilustra a área de maior destaque de cada um desses provedores.




Figura 16 – Área de destaque dos principais provedores

Adaptada de: Veras (2015).

Dessa forma, a escolha entre plataformas como AWS, Microsoft Azure e GCP deve considerar as necessidades específicas de cada organização. Não há um provedor universalmente superior, mas sim aquele que melhor atende a determinado contexto de uso. Entre os fatores relevantes nessa decisão estão o tipo de aplicação a ser executada, as restrições de orçamento, o nível de conhecimento técnico da equipe, a facilidade de integração com outros sistemas e os requisitos relacionados à segurança e conformidade.

Com base nisso, esta seção tem como objetivo apresentar uma visão geral desses provedores, destacando suas principais características, diferenciais e alguns dos serviços mais relevantes disponibilizados por cada plataforma.

Cabe destacar ainda que, embora o foco esteja nesses três provedores amplamente utilizados no mercado, existem outras empresas que também desempenham papéis importantes no ecossistema de computação em nuvem, como Alibaba Cloud, IBM Cloud e Oracle Cloud. Assim, a definição do provedor mais adequado deve sempre resultar de uma análise cuidadosa das necessidades, objetivos e requisitos técnicos de cada organização.

2.3.1 Amazon Web Services (AWS)

A AWS é amplamente reconhecida como uma das principais plataformas de computação em nuvem do mundo e foi uma das pioneiras na oferta de serviços em nuvem em grande escala. A robustez de sua infraestrutura, aliada a um portfólio abrangente de soluções e a uma comunidade ativa de usuários e desenvolvedores, contribui para que a AWS seja adotada por organizações de diferentes tamanhos, desde pequenas startups até grandes corporações globais.

Com o passar dos anos, a AWS consolidou uma posição de destaque no mercado de cloud computing, mantendo uma das maiores participações globais nesse setor. Seu catálogo inclui desde serviços essenciais de infraestrutura, como computação e armazenamento, até soluções avançadas voltadas para bancos de dados gerenciados, IA, aprendizado de máquina e aplicações relacionadas à IoT. Entre os serviços mais conhecidos estão o Amazon EC2 e o Amazon S3, além de soluções de banco de dados como Amazon RDS e Amazon DynamoDB, e serviços para IoT, como o AWS IoT Core. Um dos aspectos que diferencia a AWS é a flexibilidade de sua arquitetura, que permite construir soluções personalizadas a partir da combinação de diversos serviços independentes.

A organização dos serviços da AWS segue uma estrutura modular, agrupando recursos em categorias como computação, armazenamento, bancos de dados, redes e segurança. Esse modelo facilita a escolha e o uso apenas dos componentes necessários para cada aplicação, favorecendo a criação de arquiteturas escaláveis e adaptáveis às necessidades de cada negócio. Outro ponto relevante é o constante processo de inovação da plataforma, que frequentemente lança novos recursos e aprimora os serviços existentes para acompanhar a evolução tecnológica.

Um conceito fundamental dentro da infraestrutura da AWS é o de região, que representa um conjunto de data centers localizados em diferentes partes do mundo. A seleção da região adequada pode impactar diretamente aspectos como latência de acesso, requisitos regulatórios e custos operacionais. Cada região é composta por diversas zonas de disponibilidade (availability zones – AZs), que operam de maneira isolada entre si. Essa separação permite que aplicações sejam projetadas para suportar falhas e manter altos níveis de disponibilidade.

Em relação aos custos, a AWS oferece diferentes modelos de precificação, permitindo que as organizações escolham a forma de pagamento mais adequada ao seu perfil de uso. Entre as opções disponíveis estão o pagamento conforme o consumo, instâncias reservadas e contratos de longo prazo.

Esse conjunto de alternativas possibilita maior previsibilidade financeira e controle sobre os gastos. Além disso, a plataforma disponibiliza ferramentas específicas para estimativa e planejamento de custos antes da implementação das soluções.

Para facilitar a administração do ambiente em nuvem, a AWS oferece diversas ferramentas de gerenciamento e monitoramento. O AWS management console fornece uma interface gráfica centralizada para controlar os serviços da plataforma. Já o AWS CloudTrail registra as atividades realizadas na conta, permitindo auditoria e rastreabilidade das ações, enquanto o Amazon CloudWatch monitora métricas de desempenho e disponibilidade, auxiliando na identificação de problemas e na otimização do ambiente.

Entre os serviços mais importantes da AWS estão aqueles relacionados à computação, como o Amazon EC2 e o AWS Lambda. Embora ambos forneçam recursos de processamento na nuvem, eles possuem características e finalidades distintas.

O Amazon EC2 é um dos serviços mais populares da AWS e permite a criação e execução de VMs na nuvem. Por meio dele, os usuários podem configurar instâncias com diferentes capacidades de processamento, memória, armazenamento e rede, além de escolher o sistema operacional e os softwares que serão executados. Esse nível de controle oferece grande flexibilidade para adaptar a infraestrutura às necessidades específicas de cada aplicação.

Outra característica importante do EC2 é a variedade de tipos de instâncias disponíveis, que podem ser otimizadas para diferentes tipos de cargas de trabalho, como processamento intensivo, aplicações que exigem grande quantidade de memória ou tarefas relacionadas a gráficos. O serviço também permite ajustar rapidamente a quantidade de instâncias em funcionamento, aumentando ou reduzindo os recursos de acordo com a demanda. O modelo de cobrança é baseado no tempo de uso, seguindo o princípio de pagamento conforme o consumo.

Em contraste com o EC2, o AWS Lambda adota um modelo de computação serverless, no qual o usuário não precisa gerenciar servidores ou infraestrutura. Nesse caso, o desenvolvedor envia apenas o código da aplicação, que é executado pela plataforma em resposta a eventos específicos, como o envio de arquivos, alterações em bancos de dados ou chamadas de APIs. Esse modelo torna o Lambda especialmente adequado para aplicações que exigem escalabilidade automática e disponibilidade elevada sem a necessidade de administração direta da infraestrutura. O sistema executa as funções sob demanda, alocando recursos dinamicamente conforme o volume de requisições.

A forma de cobrança do Lambda baseia-se no número de execuções e no tempo de processamento utilizado em cada execução. Dessa maneira, o usuário paga somente pelo tempo efetivo de uso do recurso computacional. Esse modelo pode resultar em economia significativa quando comparado ao uso contínuo de VMs, principalmente em aplicações com demanda variável ou intermitente. O serviço é frequentemente utilizado em tarefas como processamento de dados, manipulação de imagens e integração entre diferentes serviços da própria AWS.

A decisão entre utilizar EC2 ou Lambda depende principalmente das necessidades da aplicação. Quando se deseja maior controle sobre o ambiente de execução e sobre a configuração da infraestrutura, o EC2 costuma ser a opção mais adequada. Por outro lado, quando o objetivo é simplificar a operação e utilizar um modelo de execução baseado em eventos, o Lambda pode oferecer vantagens significativas. Em muitos cenários, a combinação dos dois serviços resulta em arquiteturas mais eficientes e flexíveis.

Além dos serviços de computação, a AWS disponibiliza diversas soluções de armazenamento em nuvem. Entre as mais utilizadas estão o Amazon S3 (simple storage service) e o Amazon Elastic Block Store (EBS). Embora ambos tenham como finalidade o armazenamento de dados, eles diferem significativamente em sua arquitetura e nos cenários de aplicação.

O Amazon S3 é um serviço de armazenamento de objetos altamente escalável e durável, amplamente utilizado para guardar grandes volumes de dados não estruturados, como arquivos de imagem, vídeos, documentos, registros de log e backups. Nesse modelo, os dados são armazenados como objetos independentes, cada um identificado por uma chave única e acompanhado de metadados, o que facilita a organização e o gerenciamento das informações.

Outro recurso importante do S3 é a possibilidade de escolher diferentes classes de armazenamento, permitindo equilibrar custo e frequência de acesso aos dados. Classes como Standard são destinadas a dados acessados com maior frequência, enquanto opções como Amazon S3 Glacier e Amazon S3 Glacier Deep Archive são voltadas para arquivamento de longo prazo, oferecendo custos menores para dados acessados raramente. O serviço também incorpora mecanismos de segurança avançados, incluindo criptografia de dados e controle de acesso baseado em permissões.

Por outro lado, o Amazon Elastic Block Store é um serviço de armazenamento em bloco projetado principalmente para ser utilizado em conjunto com instâncias do Amazon EC2. Nesse modelo, os volumes funcionam de forma semelhante a discos rígidos virtuais, podendo ser anexados a uma máquina virtual para armazenar dados de maneira persistente.

Mesmo quando uma instância é desligada ou reiniciada, os dados armazenados em um volume EBS permanecem disponíveis, o que o torna adequado para aplicações que exigem consistência e confiabilidade. Esse tipo de armazenamento é frequentemente utilizado para sistemas operacionais, bancos de dados e aplicações que necessitam de alto desempenho e baixa latência.

Para atender a diferentes necessidades de desempenho, o EBS disponibiliza vários tipos de volumes, incluindo opções de uso geral, volumes otimizados para alto desempenho e volumes configurados com IOPS provisionadas. O serviço também permite a criação de snapshots, facilitando operações de backup e recuperação de dados, além de oferecer suporte à criptografia para proteção das informações.

De forma resumida, o Amazon S3 é mais indicado para o armazenamento de objetos e dados não estruturados, enquanto o Amazon Elastic Block Store atende principalmente às necessidades de armazenamento em bloco associadas às instâncias do Amazon EC2. Em muitas arquiteturas em nuvem, a utilização combinada desses serviços proporciona uma solução de armazenamento mais completa, flexível e adequada às diferentes demandas das aplicações.



Saiba mais

Para explorar outros serviços de computação em nuvem oferecidos por provedores como a AWS e seus concorrentes, uma boa referência é:

PINTO, O. P. *Curso de cloud computing: dominando AWS, Azure e Google Cloud: aprenda na prática os três principais provedores de nuvem*. Orlando, 2025.

2.3.2 Microsoft Azure

A Microsoft Azure ocupa a posição de segundo maior provedor de computação em nuvem no mercado, oferecendo um portfólio abrangente de serviços voltados a empresas de diferentes tamanhos e setores. Sua forte integração com o ecossistema da Microsoft é um dos principais diferenciais, garantindo compatibilidade nativa com ferramentas amplamente utilizadas no ambiente corporativo, como o Active Directory e o Visual Studio. Esse alinhamento torna a plataforma especialmente atrativa para organizações que já utilizam tecnologias da empresa.

Do ponto de vista estrutural, o Azure disponibiliza uma ampla gama de serviços com foco em aplicações empresariais, segurança e integração. Sua arquitetura prioriza a interoperabilidade entre componentes, promovendo uma experiência mais coesa quando comparada a abordagens baseadas em serviços mais independentes, como ocorre tradicionalmente na AWS. Esse modelo integrado contribui para o desenvolvimento de soluções complexas, facilita o gerenciamento centralizado e permite uma integração mais fluida com ambientes locais, favorecendo uma migração gradual para a nuvem.

Em termos de infraestrutura global, a plataforma adota o conceito de regiões e zonas de disponibilidade. As regiões correspondem a conjuntos de data centers distribuídos geograficamente, enquanto as zonas de disponibilidade representam data centers fisicamente separados dentro de uma mesma região. A utilização dessas zonas permite a construção de aplicações resilientes, com maior tolerância a falhas. A seleção adequada desses elementos é essencial para reduzir latência, atender exigências regulatórias e otimizar custos.

No que se refere à cobrança, o Azure utiliza um modelo baseado no consumo efetivo dos recursos. Entre as opções disponíveis estão o pagamento sob demanda (pay as you go), reservas e contratos de longo prazo. A plataforma também disponibiliza ferramentas para estimativa e controle de custos, aumentando a previsibilidade financeira. Além disso, oferece diferentes planos de suporte com níveis variados de SLA, adaptando-se às necessidades específicas de cada organização.

Como principal interface de gerenciamento, o Portal do Azure permite a administração centralizada dos recursos por meio de uma interface web intuitiva. Além disso, disponibiliza ferramentas de linha de comando e APIs para automação e integração com outros sistemas. O Azure Monitor complementa esse

ecossistema ao oferecer funcionalidades de monitoramento, coleta de logs e análise de desempenho, facilitando a identificação de falhas e gargalos.

No campo da computação, o Azure oferece diferentes alternativas para execução de aplicações. Entre os serviços mais relevantes estão o Azure Virtual Machines e o Azure App Service, cada um voltado a cenários específicos e níveis distintos de abstração da infraestrutura.

As VMs do Azure consistem em ambientes altamente configuráveis, permitindo controle completo sobre sistema operacional, rede, armazenamento e softwares instalados. Estão disponíveis em diversos tamanhos, com combinações variadas de CPU, memória e disco, atendendo a diferentes demandas. Esse modelo é especialmente indicado para aplicações que exigem alto grau de personalização, como sistemas legados e bancos de dados.

Essas VMs podem ser criadas e gerenciadas por meio do portal, ferramentas de linha de comando ou APIs. Recursos como backup automático, escalabilidade e alta disponibilidade podem ser ajustados conforme a necessidade. O modelo de cobrança, baseado no tempo de uso, possibilita otimizar custos ao adequar a capacidade contratada à demanda.

Por outro lado, o Azure App Service representa uma abordagem de PaaS, focada em simplificar o desenvolvimento e a implantação de aplicações web e móveis. Nesse contexto, a infraestrutura é abstraída, permitindo que o desenvolvedor concentre esforços na lógica da aplicação. O serviço oferece suporte a diversas linguagens e frameworks, como .NET, Java, PHP, Python e Node.js.

Entre as funcionalidades do app service destacam-se integração com pipelines de CI/CD, escalabilidade automática, balanceamento de carga e monitoramento nativo. Além disso, há forte integração com serviços como o Azure SQL Database e o Azure Cosmos DB, facilitando a construção de soluções completas. A precificação é estruturada em planos que variam conforme recursos e nível de escalabilidade.

A decisão entre utilizar VMs ou app service depende diretamente do contexto da aplicação. Soluções que demandam maior controle tendem a se beneficiar das VMs, enquanto aplicações que priorizam agilidade e simplicidade operacional são mais adequadas ao app service. Em muitos casos, a combinação dessas abordagens pode resultar em maior eficiência.

No que diz respeito ao armazenamento, o Azure disponibiliza serviços distintos para diferentes necessidades. Entre os mais utilizados estão o Azure Blob Storage e o Azure Files, ambos projetados para oferecer escalabilidade, durabilidade e segurança, mas com finalidades específicas.

O blob storage é um serviço de armazenamento de objetos altamente escalável e com bom custo-benefício, semelhante ao Amazon S3. Ele é ideal para armazenar grandes volumes de dados não estruturados, como imagens, vídeos, backups e logs. Os dados são organizados em blobs, que incluem conteúdo binário e metadados.

Existem diferentes tipos de blobs, adequados a variados cenários. Blobs de bloco são indicados para arquivos que podem ser segmentados, blobs de página atendem a cenários com atualizações frequentes, e blobs de append são voltados a registros incrementais, como logs. O serviço também oferece diferentes camadas de acesso e opções de redundância, permitindo equilibrar custo e desempenho.

Já o Azure Files fornece um serviço de compartilhamento de arquivos totalmente gerenciado, compatível com o protocolo SMB. Essa compatibilidade permite acesso nativo por sistemas Windows, Linux e macOS, sendo ideal para cenários que exigem compartilhamento entre aplicações, usuários e VMs.

Assim como outros serviços de armazenamento da plataforma, o Azure Files oferece diferentes níveis de desempenho e redundância, além de mecanismos de segurança como criptografia e controle de acesso baseado em identidade. Sua integração com o Active Directory facilita a gestão de permissões em ambientes corporativos.

De forma geral, o blob storage é mais indicado para dados não estruturados em grande escala, enquanto o Azure Files atende melhor a cenários de compartilhamento de arquivos tradicionais. A escolha entre eles depende do tipo de dado e da forma de acesso, sendo comum a utilização conjunta em arquiteturas mais completas e eficientes.

2.3.3 Google Cloud Platform (GCP)

O GCP é o terceiro maior player no mercado de computação em nuvem, conhecido por sua infraestrutura robusta e sua expertise em big data, análise de dados e processamento em larga escala. A plataforma se destaca pelo uso de tecnologias avançadas em IA, aprendizado de máquina e análise de grandes volumes de dados, tornando-se uma alternativa estratégica para organizações que demandam alto desempenho e escalabilidade.

Construído sobre a infraestrutura global do Google, o GCP reflete a experiência da empresa no desenvolvimento de algoritmos de alta performance e no processamento massivo de dados. Essa expertise se traduz em serviços altamente escaláveis e resilientes, amplamente utilizados em cenários que envolvem análise avançada, automação inteligente e aplicações orientadas a dados.

Uma característica marcante do GCP é sua forte orientação a arquiteturas baseadas em microsserviços e contêineres. O Google Kubernetes Engine (GKE) é um dos principais serviços da plataforma, oferecendo gerenciamento completo da orquestração de contêineres Kubernetes. A integração com ferramentas consolidadas, como Docker e Helm, simplifica os processos de desenvolvimento, implantação e operação de aplicações distribuídas. Essa abordagem modular favorece a escalabilidade, a resiliência e a adaptação dinâmica das aplicações às variações de demanda.

No contexto de big data e análise de dados, o GCP apresenta um portfólio consolidado de serviços. O Google BigQuery é um serviço de data warehouse totalmente gerenciado, reconhecido por sua alta capacidade de processamento e escalabilidade. Ele possibilita a análise de grandes volumes de dados de forma rápida e eficiente, utilizando SQL padrão. A integração com tecnologias amplamente utilizadas no ecossistema de dados, como Apache Spark e Hadoop, amplia a flexibilidade para o processamento de dados provenientes de diferentes fontes e formatos.

Em relação aos serviços de computação, o GCP disponibiliza o GCE, um serviço de VMs comparável ao Amazon EC2 e às VMs do Azure. O GCE permite a criação e o gerenciamento de VMs com diferentes configurações de CPU, memória, armazenamento e sistema operacional, atendendo a variados tipos de cargas de trabalho. A integração nativa com outros serviços da plataforma, como o GKE e o Cloud Storage, facilita o desenvolvimento e a implantação de aplicações distribuídas e de maior complexidade.

O modelo de precificação do GCP é baseado no consumo dos recursos utilizados, oferecendo diferentes opções de pagamento e mecanismos de estimativa de custos. A transparência na precificação contribui para o planejamento financeiro e a gestão eficiente dos recursos. Além disso, a plataforma disponibiliza diferentes planos de suporte, com variados níveis de SLA, adequados às necessidades de organizações de diferentes portes.

O Google Cloud Console é a principal interface web para o gerenciamento dos recursos do GCP. A ferramenta oferece uma experiência intuitiva para criação, configuração e monitoramento dos serviços. Complementarmente, o GCP disponibiliza ferramentas de linha de comando e APIs que viabilizam automação e integração com sistemas externos. O Cloud Monitoring fornece recursos de monitoramento e coleta de logs, permitindo o acompanhamento do desempenho e a rápida identificação de falhas operacionais.

O GCP oferece múltiplos modelos de execução de aplicações, que variam desde ambientes totalmente gerenciados até soluções sem servidor. Entre as opções mais utilizadas estão o GCE e o Google Cloud Functions. A escolha entre essas alternativas depende dos requisitos de controle, escalabilidade e complexidade das aplicações.

O GCE dá elevado nível de controle e personalização do ambiente de execução. As VMs podem ser configuradas com diferentes perfis de desempenho, otimizados para processamento, memória ou armazenamento. Essa flexibilidade torna o GCE adequado para aplicações complexas, sistemas legados e workloads que demandam configurações específicas de hardware e software. O serviço oferece recursos como escalabilidade automática, balanceamento de carga e backups, assegurando alta disponibilidade e estabilidade operacional.

As Google Cloud Functions representam o modelo de computação sem servidor do GCP, permitindo a execução de código em resposta a eventos. Nesse modelo, a infraestrutura subjacente é completamente abstraída, sendo necessário apenas definir o código e os gatilhos de execução. As Cloud Functions são especialmente indicadas para aplicações orientadas a eventos, como processamento de dados em tempo real, automação de tarefas e integrações entre serviços. A escalabilidade ocorre de forma automática, e o modelo de cobrança considera apenas o tempo de execução e o número de invocações, o que favorece a redução de custos em cenários de carga variável.

De forma geral, o GCE é mais indicado para aplicações que exigem maior controle e customização, enquanto as Cloud Functions atendem melhor a cenários event-driven, que priorizam simplicidade operacional e escalabilidade automática. Em determinadas arquiteturas, a combinação desses serviços pode resultar em soluções mais eficientes e flexíveis.

No que se refere ao armazenamento, o GCP disponibiliza diversas opções para atender a diferentes necessidades, desde o armazenamento de objetos até soluções de armazenamento persistente para VMs. Entre os principais serviços destacam-se o Cloud Storage e o Persistent Disk.

O Cloud Storage é um serviço de armazenamento de objetos altamente escalável, durável e economicamente eficiente, comparável ao Amazon S3 e ao Azure Blob Storage. Ele é indicado para o armazenamento de grandes volumes de dados não estruturados, como imagens, vídeos, backups, arquivos de log e dados analíticos. O serviço oferece diferentes classes de armazenamento, ajustadas conforme a frequência de acesso e o custo:

- **Standard:** voltado a dados acessados com frequência, com alta disponibilidade e baixa latência.
- **Nearline:** indicado para dados acessados ocasionalmente, com custo reduzido.
- **Coldline:** adequado para dados raramente acessados, com menor custo de armazenamento.
- **Archive:** destinado a dados acessados muito esporadicamente, com o menor custo e maior tempo de recuperação.

O Cloud Storage conta com recursos avançados de segurança, como criptografia de dados em repouso e em trânsito, além de controle de acesso baseado em identidade. Sua escalabilidade praticamente ilimitada permite o armazenamento de grandes volumes de dados sem preocupações com capacidade. A integração com serviços como BigQuery e Dataflow potencializa a análise e o processamento dos dados armazenados.

O Persistent Disk é um serviço de armazenamento em bloco projetado para fornecer armazenamento persistente às VMs do GCE. Diferentemente do Cloud Storage, que utiliza o modelo de objetos, o Persistent Disk opera como um disco de bloco, possibilitando acesso com baixa latência e alto desempenho. Esse serviço é amplamente utilizado para sistemas operacionais, bancos de dados e aplicações que demandam acesso intensivo a dados.

O Persistent Disk oferece diferentes tipos de discos, incluindo SSDs e HDDs, permitindo a adequação entre desempenho e custo conforme a necessidade. Os mecanismos de segurança incluem criptografia de dados e controle de acesso baseado em identidade, assegurando a proteção das informações armazenadas. A integração direta com o GCE simplifica a criação, o gerenciamento e a escalabilidade dos discos persistentes.

Em síntese, o Cloud Storage é mais adequado para o armazenamento de grandes volumes de dados não estruturados, enquanto o Persistent Disk atende a cenários que exigem armazenamento persistente de alto desempenho para VMs. A escolha entre esses serviços depende do tipo de dado e do padrão de acesso requerido, sendo comum sua utilização conjunta em arquiteturas de nuvem mais completas e eficientes.

2.4 Impacto da nuvem no ambiente corporativo

A computação em nuvem vem promovendo, nas últimas décadas, uma transformação profunda no ambiente corporativo, alterando modelos de negócio, estruturas organizacionais e estratégias de TI. Esse avanço redefiniu a forma como os serviços de TI são oferecidos e consumidos, substituindo o modelo tradicional baseado em infraestrutura própria por um formato no qual recursos como servidores, bancos de dados e aplicações são acessados remotamente e sob demanda.

Fato é que a infraestrutura de TIC assume um papel fundamental no desenvolvimento econômico, especialmente em um cenário contemporâneo marcado pela ampla disseminação da internet e das comunicações móveis, que ampliam o alcance e a eficiência das atividades empresariais.

Em um primeiro momento, muitas organizações apresentaram certa resistência em adotar as soluções de nuvem, principalmente devido a preocupações relacionadas à segurança e à dependência de conectividade. Com o tempo, entretanto, esse modelo evoluiu significativamente, tornando-se capaz de suportar desde aplicações críticas até operações em larga escala. Essa consolidação foi impulsionada não apenas por avanços tecnológicos, mas também pela necessidade crescente de maior agilidade, competitividade e uso estratégico de dados.

A adoção desse paradigma flexível permite às empresas explorar melhor os recursos tecnológicos, reduzindo custos operacionais e diminuindo a complexidade associada à manutenção de infraestrutura física. Dessa forma, a computação em nuvem representa uma mudança estratégica importante, ao permitir que as organizações concentrem seus esforços na inovação e no crescimento do negócio.

Entre os efeitos mais evidentes está a transição do modelo tradicional de infraestrutura para um modelo orientado a serviços. No passado, era necessário realizar investimentos elevados em hardware, redes e equipes especializadas, além de enfrentar longos ciclos de planejamento. Com a nuvem, os recursos passam a ser consumidos conforme a demanda, permitindo pagamento proporcional ao uso e rápida expansão da capacidade. Essa elasticidade contribui para maior eficiência operacional e melhor adaptação às mudanças do mercado.



Lembrete

A computação em nuvem impulsiona a servitização, ao transformar recursos de TI em serviços sob demanda, permitindo que empresas consumam tecnologia de forma flexível, escalável e orientada ao uso, em vez de adquiri-la como infraestrutura própria.

Outro aspecto relevante é o impacto na inovação e na velocidade de desenvolvimento. As plataformas em nuvem disponibilizam recursos avançados, como IA, aprendizado de máquina, computação de alto desempenho e ambientes de desenvolvimento integrados, que antes eram restritos a grandes organizações. Esse cenário reduz barreiras de entrada, permitindo que empresas de diferentes portes experimentem novas ideias, desenvolvam soluções rapidamente e lancem produtos em ciclos mais

curtos, fortalecendo a competitividade. A figura a seguir destaca essa integração entre computação em nuvem, IA e o desenvolvimento de soluções para a tomada de decisão orientada por dados.




Figura 17 – Evolução da IA e desenvolvimento com a computação em nuvem

Disponível em: <https://tinyurl.com/5f86xcb5>. Acesso em: 25 maio 2026.

Além disso, a computação em nuvem transformou as formas de trabalho, incentivando a colaboração remota e a mobilidade. Com aplicações acessíveis de qualquer lugar, equipes podem atuar de forma distribuída, utilizando ferramentas compartilhadas para comunicação e execução de tarefas. Esse movimento foi intensificado durante a pandemia de covid-19, que acelerou a adoção de soluções em nuvem e consolidou modelos híbridos de trabalho baseados em conectividade e disponibilidade contínua.

Por outro lado, a migração para a nuvem também apresenta desafios, especialmente em relação à segurança, privacidade e governança de dados. Embora os provedores ofereçam mecanismos avançados de proteção, como criptografia e autenticação multifator (MFA), a responsabilidade pela segurança é compartilhada. Isso exige que as organizações revisem suas políticas internas e estejam em conformidade com regulamentações como a LGPD e o GDPR, além de adotarem boas práticas de controle de acesso e monitoramento.

Outro ponto importante refere-se às mudanças na estrutura organizacional e na cultura corporativa. Com a adoção da nuvem, as equipes de TI deixam de atuar apenas na manutenção de infraestrutura e passam a desempenhar funções mais estratégicas, voltadas a arquitetura de soluções, gestão de serviços e inovação. Esse novo cenário demanda o desenvolvimento de competências em áreas como automação, microsserviços e DevOps, sendo determinante para o sucesso na utilização plena da nuvem.

Adicionalmente, a computação em nuvem fortalece modelos de negócio orientados a dados. Ao permitir o armazenamento e processamento de grandes volumes de informação, juntamente com ferramentas analíticas escaláveis, as empresas conseguem extrair insights valiosos para otimizar processos e apoiar a tomada de decisões. Em diversos setores, essa capacidade tornou-se essencial para aumentar a eficiência e identificar novas oportunidades.

Por fim, o impacto da computação em nuvem no ambiente corporativo pode ser entendido como uma transformação estrutural ampla, que vai além da tecnologia. Trata-se de uma mudança na forma como as organizações operam, inovam e competem. Ao proporcionar escalabilidade, flexibilidade, redução de custos e suporte à inovação, a nuvem consolidou-se como um elemento central na estratégia empresarial contemporânea, contribuindo para a construção de organizações mais eficientes, resilientes e preparadas para um cenário em constante evolução.

2.5 Panorama atual: do on-premises ao multicloud

O cenário contemporâneo na área de TI evidencia uma mudança progressiva entre diferentes paradigmas de computação, que vai desde o modelo tradicional on-premises até arquiteturas híbridas e ambientes multicloud amplamente distribuídos. Essa evolução reflete a busca constante das organizações por maior flexibilidade, eficiência e capacidade de adaptação às demandas do mercado digital.

Historicamente, as empresas operavam com infraestruturas locais, nas quais servidores, redes e sistemas eram instalados e mantidos dentro de seus próprios data centers. Esse modelo, conhecido como on-premises, garantia controle total sobre os recursos e atendia adequadamente às exigências de segurança e privacidade em um contexto menos dinâmico. Contudo, com o avanço da transformação digital, tornou-se evidente a necessidade de soluções mais escaláveis, ágeis e economicamente eficientes, impulsionando a adoção da computação em nuvem.

Nos estágios iniciais, a nuvem foi incorporada de forma complementar ao ambiente local. Muitas organizações passaram a utilizá-la para finalidades específicas, como hospedagem de sites, realização de backups, execução de testes ou suporte a aplicações não críticas. Essa estratégia permitiu explorar os benefícios da nuvem de maneira gradual, sem abandonar completamente a infraestrutura existente, especialmente em setores com fortes requisitos regulatórios ou dependência de sistemas legados.

De fato, com a evolução dos serviços oferecidos por provedores como a AWS, o Microsoft Azure e o GCP, que passaram a incorporar recursos avançados e elevados padrões de segurança e conformidade, a nuvem deixou de ser apenas uma alternativa pontual e passou a ocupar um papel central nas estratégias empresariais.

Esse movimento contribuiu para a consolidação do modelo híbrido, no qual ambientes locais são integrados a serviços de nuvem pública. Essa abordagem permite equilibrar controle e flexibilidade, mantendo sistemas críticos em infraestrutura própria enquanto direciona aplicações mais dinâmicas para a nuvem. Como resultado, as organizações conseguem otimizar custos, melhorar o desempenho e aumentar a resiliência, distribuindo cargas de trabalho conforme a necessidade e facilitando a modernização gradual de seus sistemas.

À medida que as soluções em nuvem amadureceram, emergiu um cenário ainda mais sofisticado: o multicloud. Nesse modelo, as empresas utilizam simultaneamente múltiplos provedores de nuvem, combinando serviços de diferentes plataformas conforme suas necessidades. Diferentemente do modelo

híbrido, que integra nuvem e ambiente local, o multicloud envolve a utilização de diversos provedores para ampliar a flexibilidade, evitar dependência tecnológica e otimizar desempenho e custos.

A adoção dessa estratégia está fortemente associada à busca por maior resiliência e liberdade de escolha. Ao distribuir suas operações entre diferentes provedores, as organizações podem selecionar soluções específicas mais adequadas para cada caso, como serviços avançados de IA, infraestrutura de alto desempenho ou ferramentas especializadas de análise de dados. Além disso, essa diversificação reduz riscos associados à dependência de um único fornecedor e amplia o poder de negociação em termos de custos.

Por outro lado, o uso de múltiplas nuvens também introduz desafios relevantes, principalmente relacionados à complexidade de gestão. Administrar diferentes plataformas exige ferramentas robustas de monitoramento, automação, governança e segurança, uma vez que cada provedor possui suas próprias políticas, modelos de acesso e configurações. Nesse contexto, equipes de TI precisam desenvolver novas competências, incluindo arquitetura distribuída, integração entre sistemas, práticas de DevOps e automação baseada em IaC. Além disso, garantir segurança e conformidade torna-se mais desafiador, devido ao aumento da superfície de ataque e da diversidade de configurações possíveis.

Outro elemento importante nesse panorama é a permanência dos sistemas legados. Muitas organizações continuam operando parte de suas aplicações em ambientes locais, seja por limitações técnicas, alto nível de customização ou dependência de hardware específico. Nesses casos, a migração completa para a nuvem pode não ser viável no curto prazo. Assim, modelos híbridos e multicloud permitem uma transição gradual, na qual sistemas tradicionais coexistem com aplicações modernas desenvolvidas diretamente na nuvem.

Paralelamente, observa-se uma mudança significativa no papel da tecnologia dentro das organizações. A TI deixou de ser apenas um suporte operacional e passou a assumir uma função estratégica, essencial para inovação, eficiência e geração de valor. A transição do modelo on-premises para ambientes distribuídos envolve não apenas mudanças tecnológicas, mas também transformações culturais e organizacionais, incluindo a adoção de metodologias ágeis, práticas de automação, cultura DevOps e capacitação contínua das equipes.

Conclui-se que o cenário atual da TI reflete uma trajetória evolutiva que parte de infraestruturas locais e avança em direção a ambientes distribuídos e integrados entre múltiplas nuvens. Essa transformação não se limita ao aspecto técnico, mas representa uma mudança profunda na forma como as organizações estruturam suas operações e tomam decisões estratégicas. O avanço do multicloud evidencia a maturidade das empresas na busca por soluções mais flexíveis, resilientes e alinhadas às exigências da transformação digital, consolidando-se como uma das principais tendências do setor.



Resumo

A unidade I apresentou os fundamentos da computação em nuvem, destacando sua importância no contexto atual da TI e sua evolução como modelo dominante de provisão de serviços computacionais. Inicialmente, o conteúdo contextualizou a transformação no uso da TI, evidenciando a transição de infraestruturas locais para um modelo baseado em serviços acessíveis via internet.

O texto introduziu o conceito de computação em nuvem como a disponibilização de recursos de TI sob demanda, incluindo servidores, armazenamento, redes e aplicações. Esse modelo permite que organizações utilizem recursos de forma escalável e flexível, sem a necessidade de investir em infraestrutura própria, reduzindo custos e aumentando a eficiência operacional.

A unidade abordou a origem da computação em nuvem, relacionando-a a conceitos anteriores, como o utility computing e o time-sharing. Esses paradigmas históricos contribuíram para a ideia de computação como serviço, que se consolidou com o avanço da virtualização, das redes de comunicação e da internet, tornando viável a oferta de recursos computacionais em larga escala. A evolução tecnológica que possibilitou a consolidação da nuvem inclui o desenvolvimento de data centers automatizados, virtualização e redes de alta capacidade. Esses elementos permitiram o provisionamento dinâmico de recursos, com elasticidade e medição precisa do consumo, características fundamentais do modelo de nuvem.

Foram exploradas a expansão e adoção da computação em nuvem pelas organizações. Inicialmente vista com cautela devido a preocupações com segurança e dependência da internet, a nuvem tornou-se um modelo amplamente adotado, impulsionado pela necessidade de maior agilidade, inovação e competitividade no ambiente corporativo.

Em seguida, foram apresentadas as principais características da computação em nuvem, conforme definição do NIST. Entre elas, temos o acesso amplo via rede, a elasticidade, o autoatendimento sob demanda, o compartilhamento de recursos e o modelo de pagamento conforme o uso, que juntos definem a essência desse paradigma tecnológico.

Foram apresentados os modelos de serviço da computação em nuvem: IaaS, PaaS e SaaS. Esses modelos diferenciam-se pelo nível de controle e responsabilidade do usuário, variando desde o gerenciamento de infraestrutura até o uso de aplicações prontas disponibilizadas pela internet.

A unidade destacou ainda o papel dos principais provedores de nuvem (Amazon, Microsoft e Google), que oferecem soluções como plataformas para desenvolvimento, armazenamento e processamento de dados. Esses provedores viabilizam o acesso a tecnologias avançadas, como IA e análise de dados, democratizando o uso de recursos antes restritos a grandes organizações.

Por fim, o conteúdo evidenciou o impacto da computação em nuvem na transformação digital, ressaltando sua aplicação em diversos setores e sua importância para o desenvolvimento de soluções modernas, escaláveis e inovadoras. A nuvem foi apresentada como elemento central na infraestrutura tecnológica contemporânea, sustentando aplicações críticas e promovendo novos modelos de negócio.



Exercícios

Questão 1. (Idecan 2023, adaptada) Cloud computing (computação em nuvem) é um modelo de entrega de recursos computacionais sob demanda pela internet, que inclui servidores, armazenamento, bancos de dados, redes, software e análises, sem que o usuário precise gerenciar fisicamente esses ativos. Em vez de comprar e manter datacenters e equipamentos próprios, empresas e indivíduos podem acessar tecnologias de provedores, pagando apenas pelo que utilizam.

Nesse contexto, assinale as três principais modalidades de computação em nuvem.

- A) IoT, IaC e IaaS.
- B) FaaS, SaaS e IaC.
- C) CaaS, PaaS e On-Site.
- D) On-premises, On-Site e Colocation.
- E) PaaS, SaaS e IaaS.

Resposta correta: alternativa E.

Análise da questão

As três principais modalidades de computação em nuvem reconhecidas pelo mercado e por padrões como o do NIST são as elencadas a seguir.

- **PaaS:** oferece uma plataforma para o desenvolvimento e para a implantação de aplicativos, sem gerenciar a infraestrutura subjacente.
- **SaaS:** disponibiliza aplicações completas pela internet, como e-mails corporativos ou sistemas de gestão de relacionamento com o cliente (CRMs).
- **IaaS:** fornece infraestrutura virtualizada (servidores, rede, armazenamento) sob demanda.

Questão 2. (FGV 2024, adaptada) A estratégia de gestão de infraestrutura em TI que busca a flexibilidade operacional por meio do uso combinado de diferentes serviços de nuvem pública, como AWS, Microsoft Azure e GCP, permitindo que uma organização se beneficie das características únicas de cada serviço, conforme suas necessidades específicas, é conhecida como:

- A) Infraestructura hiperconvergente.
- B) Multicloud.
- C) Híbrida.
- D) Edge.
- E) Privada.

Resposta correta: alternativa B.

Análise da questão

O texto do enunciado descreve precisamente o conceito de multicloud. Multicloud consiste no uso combinado de diferentes serviços de nuvem de múltiplos provedores (como AWS, Azure e Google Cloud), de forma estratégica, para aproveitar as características únicas de cada um conforme as necessidades específicas da organização.

Além de evitar a dependência excessiva de um único provedor, o multicloud permite que cada carga de trabalho seja alocada no ambiente mais adequado. No entanto, essa abordagem exige um planejamento cuidadoso de governança, segurança unificada e gestão de conectividade entre nuvens.

[illegible]